VILNIAUS UNIVERSITETAS

MATEMATIKOS IR INFORMATIKOS FAKULTETAS

DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

Apsilankymo internetinėje parduotuvėje pelningumo prognozė

Laboratorinis darbas

1 grupė

Nikita Demin, Lukas Janušauskas
Edvin Liubkevič, Martynas Zabitis

Vilnius
2026

Santrauka

Aktualumas

Tikslas

Mūsų tikslas yra prognozuoti ar pirkėjas, prisijungęs prie internetinės parduotuvės, ką nors nusipirks, ir, nustatyti kokie faktoriai veikia prisijungusio naudotojo pasirinkimą.

Uždaviniai

Norint pasiekti savo užsibrėžto tikslo, išsikėlėme šiuos uždavinius:

Lentelių sąrašas

1 Kiekybinių kintamųjų skaitinės charakteristikos 6
2 Pelningų sesijų dažnių lentelė 6
3 “OperatingSystems” ir pelningumo kryžminė lentelė 7
4 “Browser” ir pelningumo kryžminė lentelė 7
5 “TrafficType” ir pelningumo kryžminė lentelė 7
A.1 “VisitorType” ir pelningumo kryžminė lentelė 11
A.2 “Region” ir pelningumo kryžminė lentelė 11
A.3 “Weekend” ir pelningumo kryžminė lentelė 12
A.4 “Month” ir pelningumo kryžminė lentelė 12

Iliustracijų sąrašas

1 Pelningo apsilankymo santykinis dažnis pagal skirtingus sesiją apibūdinančius požymius . . . 8
2 Sesijos trukmės požymių smuiko formos ir stačiakampės diagramos pagal pelningumą 9
3 Sesijos metu aplankytų puslapių požymių smuiko formos ir stačiakampės diagramos pagal pelningumą 9
4 Kuko matas su logit modeliu 10
5 Prisono liekanos su logit modeliu 10
A.1 Sesijos metu aplankytų puslapių skaičiaus pasiskirtymas kiekviename puslapio tipui 11

Turinys

Santrauka **2**

1 Tyrimas **6**
1.1 Duomenų paruošimas 6
1.2 Duomenų pradinė analizė 6

2 Išskirtys su logit modeliu **9**

3 Sąveikos **11**

A priedas **11**

B priedas **12**
3.1 DI naudojimas 12

1 Tyrimas

1.1 Duomenų paruošimas

Kintamieji „OperatingSystems“, „Browser“, „Region“, „TraficType“ yra kategoriniai kintamieji, užkoduoti natūraliais skaičiais. Todėl juos pakeičiame atitinkamais faktoriais ir vėliau iš jų formuosime fiktyvius kintamuosius. Kintamasis „SpecialDay“, sprendžiant pagal reikšmes ir aprašymą yra ranginis kitamasis įgaunantis 6 skirtingas reikšmes: $\{0;\ 0,2;\ \ldots;\ 1\}$.

Duomenų aprašyme, esančiame *UCI Irvine Machine Learning Repository* duomenų portale, autoriai teigia, kad praleistų reikšmių nėra. Mes pasitikslinome, pasileidę atitinkamą \verb|R| kodą - praleistų reikšmių nėra.

Loginių išskirčių tyrimas yra būtina dalis tyrimo, kadangi kai kurios iš duomenų rinkinyje esančios sesijos gali būti informacijos surinkimo robotai (*angl. web-scrapers*). Kad ištirtume logines išskirtis sudarėme skaitinių charakteristikų lentelę kiekybiniams kintamiesiems (1 lentelė). Joje naudojami standartiniai skaitinių charakteristikų žymėjimai: Min - minimumas, Q_n - n-tasis kvartilis, μ - vidurkis, Max - maximumas. 1 lentelėje matome, jog nėra jokių nelogiškai išsiskiriančių reikšmių kintamuosiuose nesusijusiuose su apsilankymo trukme. Tačiau kintamiesiems, susijisiems su bendra apsilankymo trukme

1 lentelė: Kiekybinių kintamųjų skaitinės charakteristikos

Kintamasis / Statistika	Min	Q_1	Q_2	μ	Q_3	Max
Administrative	0.00	0.00	1.00	2.32	4.00	27.00
Administrative_Duration	0.00	0.00	7.50	80.82	93.26	3398.75
Informational	0.0	0.0	0.0	0.5	0.0	24.0
Informational_Duration	0.00	0.00	0.00	34.47	0.00	2549.38
ProductRelated	0.00	7.00	18.00	31.73	38.00	705.00
ProductRelated_Duration	0.00	184.14	598.94	1194.75	1464.16	63973.52
BounceRates	0.00	0.00	0.00	0.02	0.02	0.20
ExitRates	0.00	0.01	0.03	0.04	0.05	0.20
PageValues	0.00	0.00	0.00	5.89	0.00	361.76
SpecialDay	0.00	0.00	0.00	0.06	0.00	1.00

Kad toliau tirtume trukmės kintamųjų logines išskirtis, **(šitą gal ir išimsiu, reikia pagal straipsnį gal būt pažiūrėti i guess)**

Toliau tirsime klasių disbalanso problemą, nes iš dažnio lentelės (2 lentelė) matome, jog turime šią problemą. Šią problemą vėliau taikysime dominuojančios klasės mažinimo būdu, kadangi turime didelį duomenų rinkinį ir taikysime statistinius metodus, kuriems paprastai užtenka nedaug duomenų.

2 lentelė: Pelningų sesijų dažnių lentelė

Pelningas apsilankymas	Dažnis	Santykinis dažnis, %
FALSE	10422	84.53
TRUE	1908	15.47

1.2 Duomenų pradinė analizė

Šioje aprašymo dalyje pateikiame tik svarbiausius akcentus, kurie mums bus svarbus, kitus grafikus, išbrėžtus duomenų pradinei tyrybai, pateiksime A priede.

Prieš taikant binarinę regresiją labai svarbu įsitikinti, kad kategorinio kintamojo lygmenų kartotinumas yra pakankamai didelis, esant visoms klasifikuojamo kintamojo reikšmėms.

Iš žemiau pateiktų lentelių, matome, kad yra probleminių faktorių lygmenų. Kintamasis „VisitorType“ turi lygmenį „Other“, kuris gali būti problemiškas, padarius dominuojančios klasės sumažinimą, taigi šį faktoriaus lygmenį pašalinsime.

Pašalinsime „OperatingSystems“, „Browser“ faktorių lygmenis, kurie turi mažiau arba lygiai 5 stebėjimus, esant pelningai sesijai. Faktorius „TrafficType“ turi daug probleminių lygmenų, taigi juos šalinant išmesime daug duomenų, todėl mes šį faktorių pašalinsime. Šių trijų minėtų faktorių dažnių lentelės pateiktos atitinkamai 3, 4 ir 5 lentelėse. Taip pat kintamojo „Month“ lygmuo „Feb“ (atitinkantis vasario mėnesį) turi tik tris stebėjimus, taigi pašalinsime ir vasario mėnesio stebėjimus. Kitos kryžminės dažnių lentelės pateiktos priede A.

3 lentelė: “OperatingSystems” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	2206	379	2585
2	5446	1155	6601
3	2287	268	2555
4	393	85	478
5	5	1	6
6	17	2	19
7	6	1	7
8	62	17	79

4 lentelė: “Browser” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	2097	365	2462
2	6738	1223	7961
3	100	5	105
4	606	130	736
5	381	86	467
6	154	20	174
7	43	6	49
8	114	21	135
9	1	0	1
10	131	32	163
11	5	1	6
12	7	3	10
13	45	16	61

5 lentelė: “TrafficType” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	2189	262	2451
2	3066	847	3913
3	1872	180	2052
4	904	165	1069
5	204	56	260
6	391	53	444
7	28	12	40
8	248	95	343
9	38	4	42
10	360	90	450
11	200	47	247
12	1	0	1
13	695	43	738
14	11	2	13

	Nepelninga	Pelninga	Bendrai
15	38	0	38
16	2	1	3
17	1	0	1
18	10	0	10
19	16	1	17
20	148	50	198

Žiūrint iš stulpelinių grafikų (žr. 1 pav.), kuriuose pavaizduota tikimybė, jog sesijoje įvyks pirkimas, pagal skirtingus kategorinius požymius. Čia pateikiame parinktus kategorinius požymius, ne visus, kadangi kiti kategoriniai požymiai buvo nereikšmingi arba trivialūs.

Matome, kad sesijos pelningumo santykinis dažnis skiriasi skirtingais mėnesiais, tai priklauso nuo internetinės parduotuvės pobūdžio, produktų kokybės, asortimento. Taip pat matome, jog naudotojai, naudojantys skirtingas operacines sistemas, turi skirtingus skonius, požiūrį, taigi ir sesijos pelningumo tikimybė skiriasi. Pakartotiniai lankytojai turi mažesnę tikimybę atlikti užsakymą, kas, gali būti paaiškinama dvejomis priežastimis: 1) pakartotiniai lankytojai gali lankytis skiltyse skirtose sekti vežamas prekes, 2) internetinės parduotuvės prekių kokybė prasta. Taip pat, svarbu paminėti, kad apsilankymai savaitgalį dažniau baigiasi užsakymu, nei darbo dienomis.

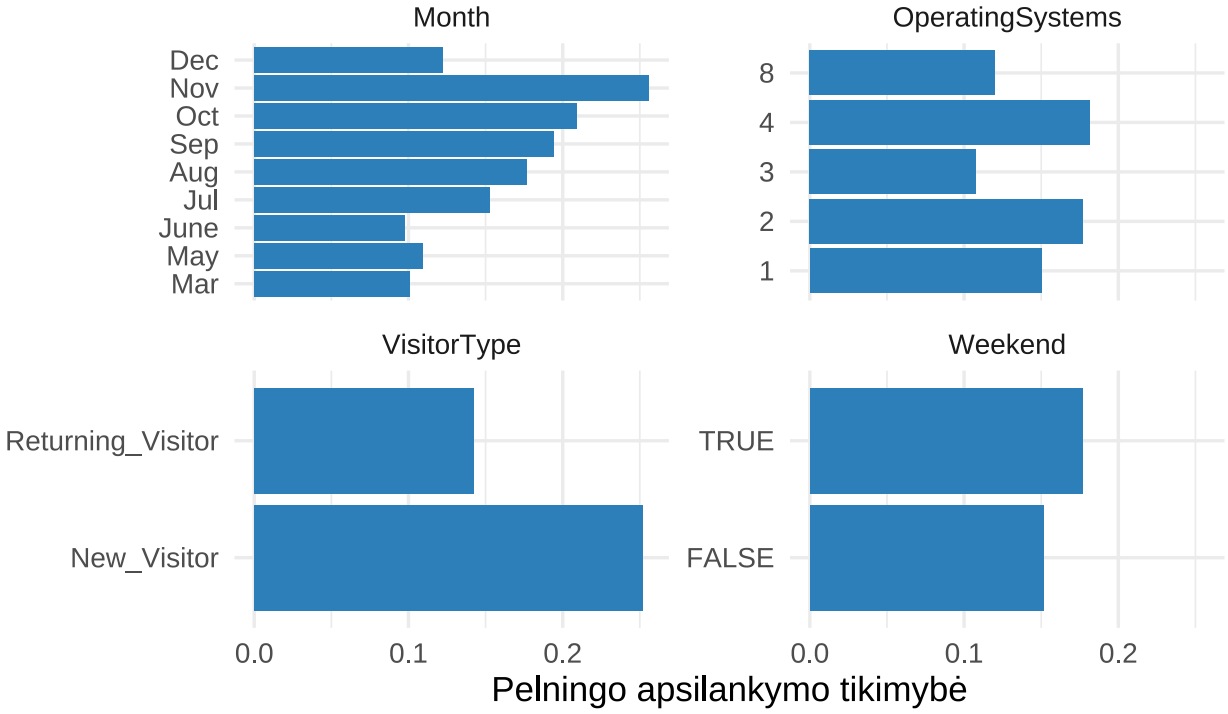

1 pav.: Pelningo apsilankymo santykinis dažnis pagal skirtingus sesiją apibūdinančius požymius

2 grafike iš kintamųjų „Administrative_Duration“, „Informational_Duration“ ir „ProductRelated_Duration“ smuiko formos ir stačiakampių grafikų matome, kad apsilankymo administraciniuose ir informaciniuose puslapiuose trukmė nedaro didelės įtakos užsakymo atlikimo tikimybei. Svarbu paminėti, kad grafike skalė logaritminė, taigi nedideli skirtumai grafike gali sąlygoti reikšmingus skirtumus pradiniuose duomenyse. Už tat, sprendžiant pagal kvartilius, matome, kad laikas, praleistas produktų puslapiuose turėtų daryti didesnę įtaką užsakymo atlikimo tikimybei.

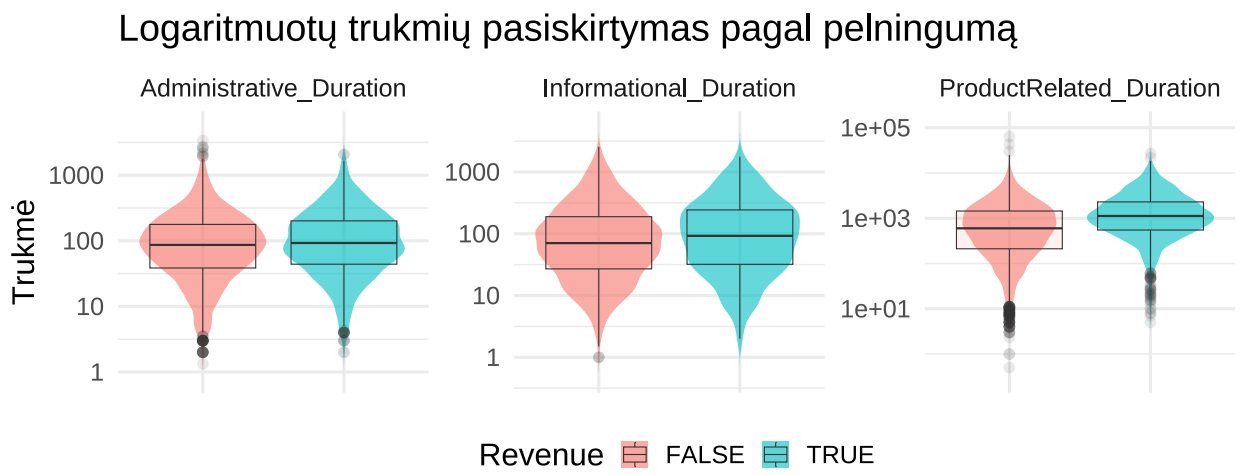

2 pav.: Sesijos trukmės požymių smuiko formos ir stačiakampės diagramos pagal pelningumą

„Google analytics“ metrikos, agreguotos kiekvienam aplankytam puslapiui sesijos metu, labiau įtakoja pasirinkimą atliksti užsakymą (žr. 3 pav.). „BounceRates“, kas yra dalis puslapių dalis, kuriuos naudotojai , neigiamai įtakoja pasirinkimą užsisakyti prekę iš parduotuvės. Taip pat neigiamai įtakoja ir „ExitRates“, kurį aprašėme duomenų aprašyme. Užtat vidutinis sesijos metu aplankytų puslapių „Google analytics“ įvertis („PageValues“) teigiamai įtakoja sesijos pelningumą.

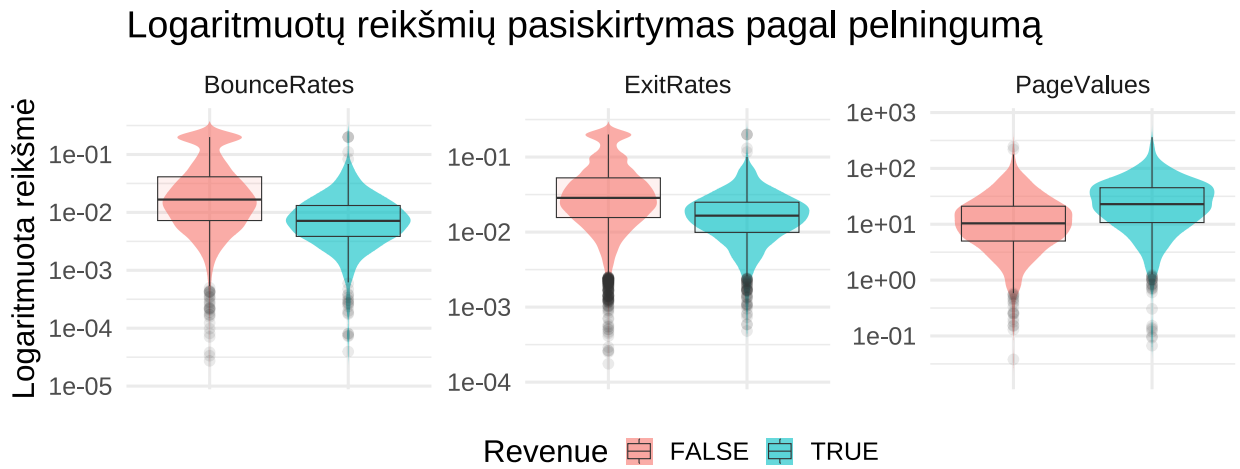

3 pav.: Sesijos metu aplankytų puslapių požymių smuiko formos ir stačiakampės diagramos pagal pelningumą

```
##
## FALSE  TRUE
##  7300  7300
```

2 Išskirtys su logit modeliu

Išskirtis tikrinsime pasitelkę Kuko matą ir Pirsono liekanas.

Pavaizdavus Kuko matą (žr. 4 pav.), negalime pastebėti jokių išskirčių. Visos reikšmės neviršija 0,05.

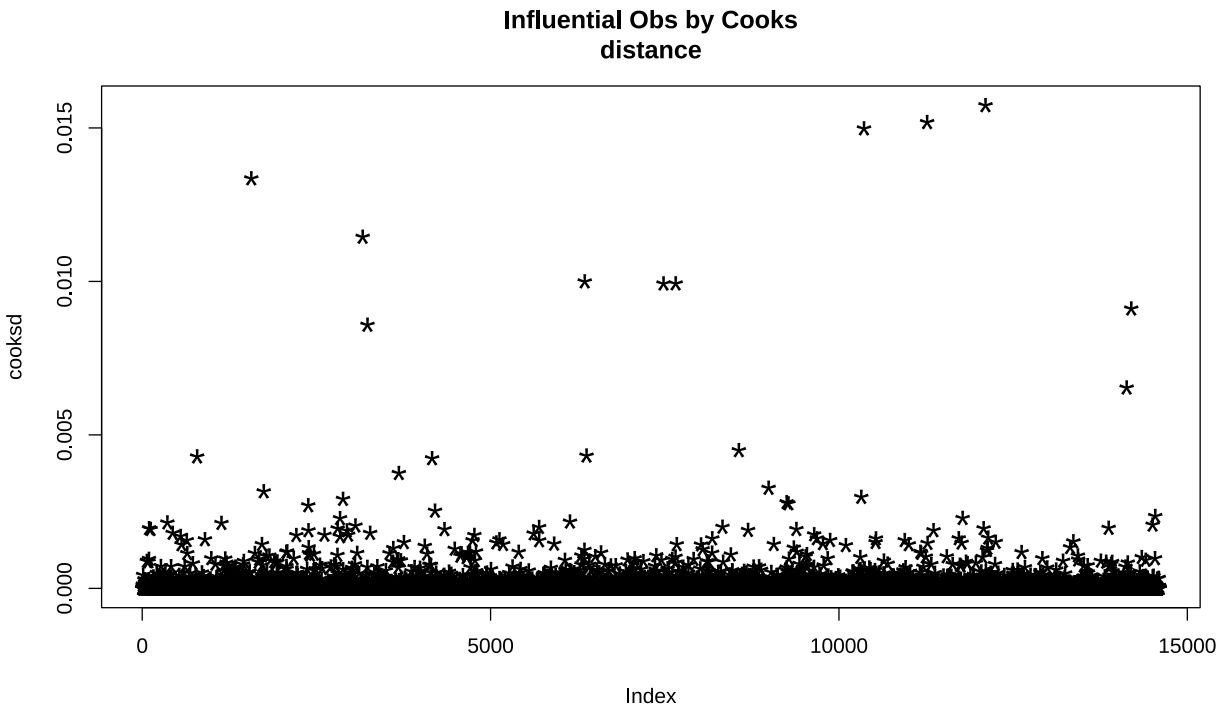

4 pav.: Kuko matas su logit modeliu

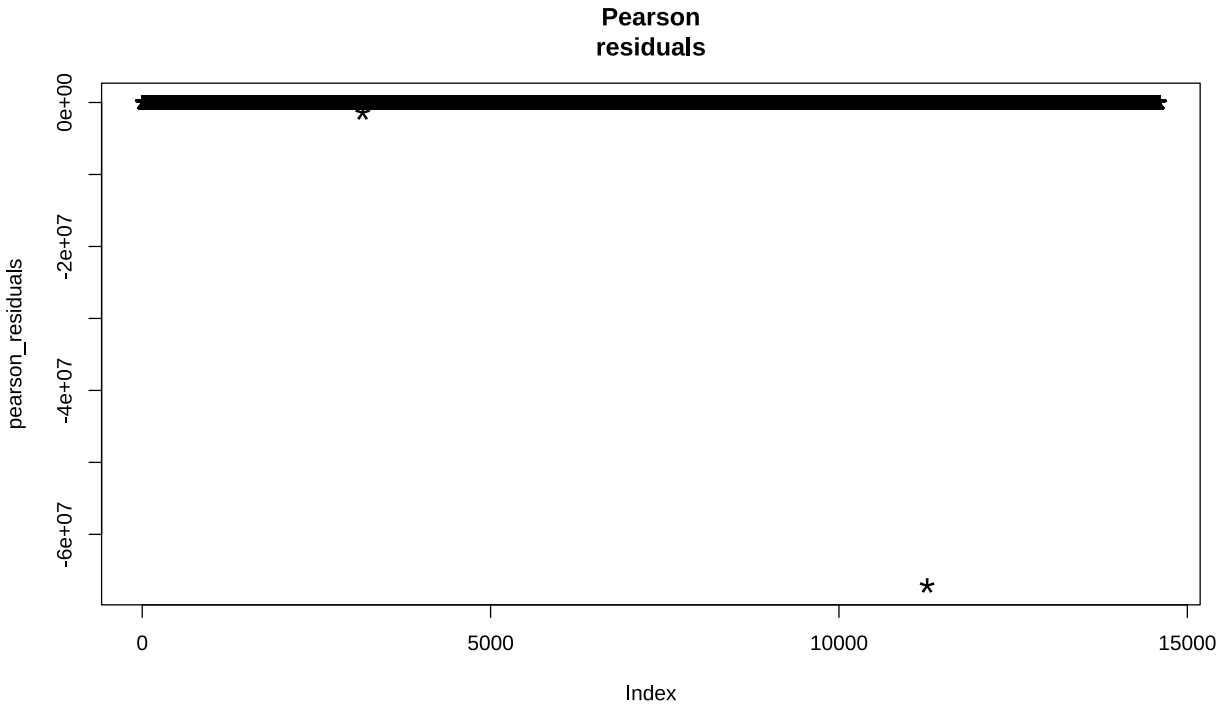

5 pav.: Prisono liekanos su logit modeliu

Ištyrę stebėjimus, kurių |Pirsono liekanos| > 3 (žr. 5 pav.), pastebėjome, kad kai kurie stebėjimai turi 0 praleisto laiko svetainėje. Taip pat turime atvejų, kai yra nurodytas konkretus praleistas laikas svetainėje,

tačiau svetainių skaičius yra 0, todėl tokius stebėjimus pašalinsime. Kiti stebėjimai su didelėmis Pearsono liekanomis nebuvo pašalinti iš analizės, kadangi duomenų patikrinimo metu nebuvo pastebėta jokių akivaizdžių duomenų įvedimo ar matavimo klaidų. Todėl daroma prielaida, kad šios reikšmės atspindi realius duomenų svyravimus, o jų pašalinimas galėtų iškreipti analizės rezultatus.

3 Sąveikos

Šiame žingsnyje buvo sukurti nauji kintamieji, kurie gali geriau atspindėti vartotojo elgseną svetainėje. Buvo apskaičiuoti trys nauji rodikliai, parodantys santykį tarp aplankytų puslapių skaičiaus ir jų peržiūros trukmės kiekvienoje kategorijoje. Taip pat sukurtas papildomas kintamasis, kuris apjungia bendrą peržiūrėtų puslapių skaičių su puslapio verte (*PageValues*), siekiant geriau įvertinti vartotojo įsitraukimą.

A priedas

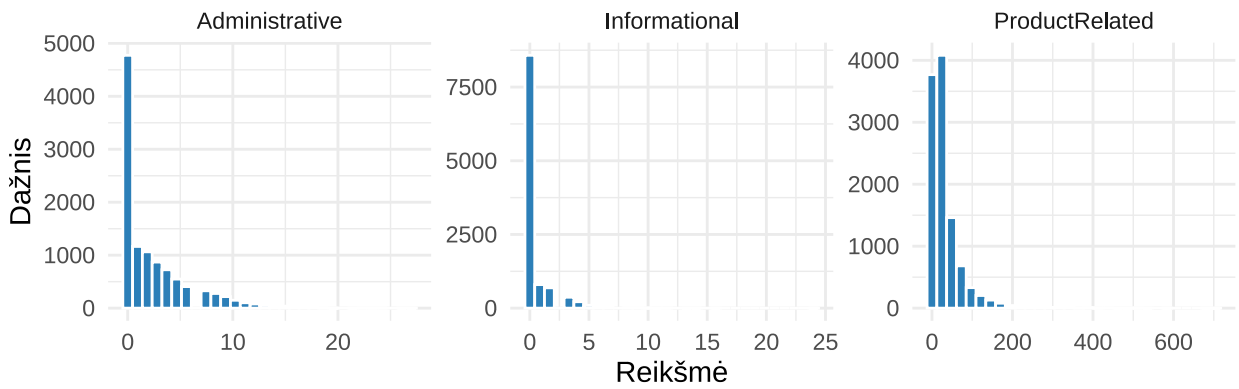

A.1 pav.: Sesijos metu aplankytų puslapių skaičiaus pasiskirtymas kiekviename puslapio tipui

A.1 lentelė: "VisitorType" ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
New_Visitor	1200	408	1608
Returning_Visitor	7925	1381	9306

A.2 lentelė: "Region" ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	3514	717	4231
2	827	178	1005
3	1803	333	2136
4	886	168	1054
5	232	49	281
6	614	109	723
7	583	116	699
8	334	53	387
9	332	66	398

A.3 lentelė: “Weekend” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
FALSE	7007	1315	8322
TRUE	2118	474	2592

A.4 lentelė: “Month” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
Mar	1514	184	1698
May	2672	349	3021
June	221	28	249
Jul	332	61	393
Aug	328	73	401
Sep	339	81	420
Oct	421	104	525
Nov	1987	713	2700
Dec	1311	196	1507

B priedas

3.1 DI naudojimas