VILNIAUS UNIVERSITETAS

MATEMATIKOS IR INFORMATIKOS FAKULTETAS

DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

Apsilankymo internetinėje parduotuvėje pelningumo prognozė

Laboratorinis darbas

1 grupė

Nikita Demin, Lukas Janušauskas
Edvin Liubkevič, Martynas Zabitis

Vilnius
2026

Santrauka

Aktualumas

Tikslas

Mūsų tikslas yra prognozuoti ar pirkėjas, prisijungęs prie internetinės parduotuvės, ką nors nusipirks, ir, nustatyti kokie faktoriai veikia prisijungusio naudotojo pasirinkimą.

Uždaviniai

Norint pasiekti savo užsibrėžto tikslo, išsikėlėme šiuos uždavinius:

Lentelių sąrašas

1 Kiekybinių kintamųjų skaitinės charakteristikos 6
2 Pelningų sesijų dažnių lentelė 6
3 “OperatingSystems” ir pelningumo kryžminė lentelė 7
4 “Browser” ir pelningumo kryžminė lentelė 7
5 “TrafficType” ir pelningumo kryžminė lentelė 7
A.1 “VisitorType” ir pelningumo kryžminė lentelė 11
A.2 “Region” ir pelningumo kryžminė lentelė 11
A.3 “Weekend” ir pelningumo kryžminė lentelė 11
A.4 “Month” ir pelningumo kryžminė lentelė 12

Iliustracijų sąrašas

1 Pelningo apsilankymo santykinis dažnis pagal skirtingus sesiją apibūdinančius požymius . . . 8

2 Sesijos trukmės požymių smuiko formos ir stačiakampės diagramos pagal pelningumą 9

3 Sesijos metu aplankytų puslapių požymių smuiko formos ir stačiakampės diagramos pagal pelningumą 9

4 Kuko matas su logit modeliu 10

5 Prisono liekanos su logit modeliu 10

A.1 Sesijos metu aplankytų puslapių skaičiaus pasiskirtymas kiekviename puslapio tipui 11

Turinys

Santrauka **2**

1 Tyrimas **6**

1.1 Duomenų paruošimas 6

1.2 Duomenų pradinė analizė 6

2 Išskirtys **9**

A priedas **11**

B priedas **12**

2.1 DI naudojimas 12

1 Tyrimas

1.1 Duomenų paruošimas

Kintamieji „OperatingSystems“, „Browser“, „Region“, „TraficType“ yra kategoriniai kintamieji, užkoduoti natūraliais skaičiais. Todėl juos pakeičiame atitinkamais faktoriais ir vėliau iš jų formuosime fiktyvius kintamuosius. Kintamasis „SpecialDay“, sprendžiant pagal reikšmes ir aprašymą yra ranginis kitamasis įgaunantis 6 skirtingas reikšmes: $\{0;\ 0,2;\ \ldots;\ 1\}$.

Duomenų aprašyme, esančiame *UCI Irvine Machine Learning Repository* duomenų portale, autoriai teigia, kad praleistų reikšmių nėra. Mes pasitikslinome, pasileidę atitinkamą \verb|R| kodą - praleistų reikšmių nėra.

Loginių išskirčių tyrimas yra būtina dalis tyrimo, kadangi kai kurios iš duomenų rinkinyje esančios sesijos gali būti informacijos surinkimo robotai (*angl. web-scrapers*). Kad ištirtume logines išskirtis sudarėme skaitinių charakteristikų lentelę kiekybiniams kintamiesiems (1 lentelė). Joje naudojami standartiniai skaitinių charakteristikų žymėjimai: Min - minimumas, Q_n - n-tasis kvartilis, μ - vidurkis, Max - maximumas. 1 lentelėje matome, jog nėra jokių nelogiškai išsiskiriančių reikšmių kintamuosiuose nesusijusiuose su apsilankymo trukme. Tačiau kintamiesiems, susijisiems su bendra apsilankymo trukme

1 lentelė: Kiekybinių kintamųjų skaitinės charakteristikos

Kintamasis / Statistika	Min	Q_1	Q_2	μ	Q_3	Max
Administrative	0.00	0.00	1.00	2.32	4.00	27.00
Administrative_Duration	0.00	0.00	7.50	80.82	93.26	3398.75
Informational	0.0	0.0	0.0	0.5	0.0	24.0
Informational_Duration	0.00	0.00	0.00	34.47	0.00	2549.38
ProductRelated	0.00	7.00	18.00	31.73	38.00	705.00
ProductRelated_Duration	0.00	184.14	598.94	1194.75	1464.16	63973.52
BounceRates	0.00	0.00	0.00	0.02	0.02	0.20
ExitRates	0.00	0.01	0.03	0.04	0.05	0.20
PageValues	0.00	0.00	0.00	5.89	0.00	361.76
SpecialDay	0.00	0.00	0.00	0.06	0.00	1.00

Kad toliau tirtume trukmės kintamųjų logines išskirtis, **(šitą gal ir išimsiu, reikia pagal straipsnį gal būt pažiūrėti i guess)**

Toliau tirsime klasių disbalanso problemą, nes iš dažnio lentelės (2 lentelė) matome, jog turime šią problemą. Šią problemą vėliau taikysime dominuojančios klasės mažinimo būdu, kadangi turime didelį duomenų rinkinį ir taikysime statistinius metodus, kuriems paprastai užtenka nedaug duomenų.

2 lentelė: Pelningų sesijų dažnių lentelė

Pelningas apsilankymas	Dažnis	Santykinis dažnis, %
FALSE	10422	84.53
TRUE	1908	15.47

1.2 Duomenų pradinė analizė

Šioje aprašymo dalyje pateikiame tik svarbiausius akcentus, kurie mums bus svarbus, kitus grafikus, išbrėžtus duomenų pradinei tyrybai, pateiksime A priede.

Prieš taikant binarinę regresiją labai svarbu įsitikinti, kad kategorinio kintamojo lygmenų kartotinumas yra pakankamai didelis, esant visoms klasifikuojamo kintamojo reikšmėms.

Iš žemiau pateiktų lentelių, matome, kad yra probleminių faktorių lygmenų. Kintamasis „VisitorType“ turi lygmenį „Other“, kuris gali būti problemiškas, padarius dominuojančios klasės sumažinimą, taigi šį faktoriaus lygmenį pašalinsime.

Pašalinsime „OperatingSystems“, „Browser“ faktorių lygmenis, kurie turi mažiau arba lygiai 5 stebėjimus, esant pelningai sesijai. Faktorius „TrafficType“ turi daug probleminių lygmenų, taigi juos šalinant išmesime daug duomenų, todėl mes šį faktorių pašalinsime. Šių trijų minėtų faktorių dažnių lentelės pateiktos atitinkamai 3, 4 ir 5 lentelėse. Taip pat kintamojo „Month“ lygmuo „Feb“ (atitinkantis vasario mėnesį) turi tik tris stebėjimus, taigi pašalinsime ir vasario mėnesio stebėjimus. Kitos kryžminės dažnių lentelės pateiktos priede A.

3 lentelė: “OperatingSystems” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	2206	379	2585
2	5446	1155	6601
3	2287	268	2555
4	393	85	478
5	5	1	6
6	17	2	19
7	6	1	7
8	62	17	79

4 lentelė: “Browser” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	2097	365	2462
2	6738	1223	7961
3	100	5	105
4	606	130	736
5	381	86	467
6	154	20	174
7	43	6	49
8	114	21	135
9	1	0	1
10	131	32	163
11	5	1	6
12	7	3	10
13	45	16	61

5 lentelė: “TrafficType” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	2189	262	2451
2	3066	847	3913
3	1872	180	2052
4	904	165	1069
5	204	56	260
6	391	53	444
7	28	12	40
8	248	95	343
9	38	4	42
10	360	90	450

	Nepelninga	Pelninga	Bendrai
11	200	47	247
12	1	0	1
13	695	43	738
14	11	2	13
15	38	0	38
16	2	1	3
17	1	0	1
18	10	0	10
19	16	1	17
20	148	50	198

Žiūrint iš stulpelinių grafikų (žr. 1 pav.), kuriuose pavaizduota tikimybė, jog sesijoje įvyks pirkimas, pagal skirtingus kategorinius požymius. Čia pateikiame parinktus kategorinius požymius, ne visus, kadangi kiti kategoriniai požymiai buvo nereikšmingi arba trivialūs.

Matome, kad sesijos pelningumo santykinis dažnis skiriasi skirtingais mėnesiais, tai priklauso nuo internetinės parduotuvės pobūdžio, produktų kokybės, asortimento. Taip pat matome, jog naudotojai, naudojantys skirtingas operacines sistemas, turi skirtingus skonius, požiūrį, taigi ir sesijos pelningumo tikimybė skiriasi. Pakartotiniai lankytojai turi mažesnę tikimybę atlikti užsakymą, kas, gali būti paaiškinama dvejomis priežastimis: 1) pakartotiniai lankytojai gali lankytis skiltyse skirtose sekti vežamas prekes, 2) internetinės parduotuvės prekių kokybė prasta. Taip pat, svarbu paminėti, kad apsilankymai savaitgalį dažniau baigiasi užsakymu, nei darbo dienomis.

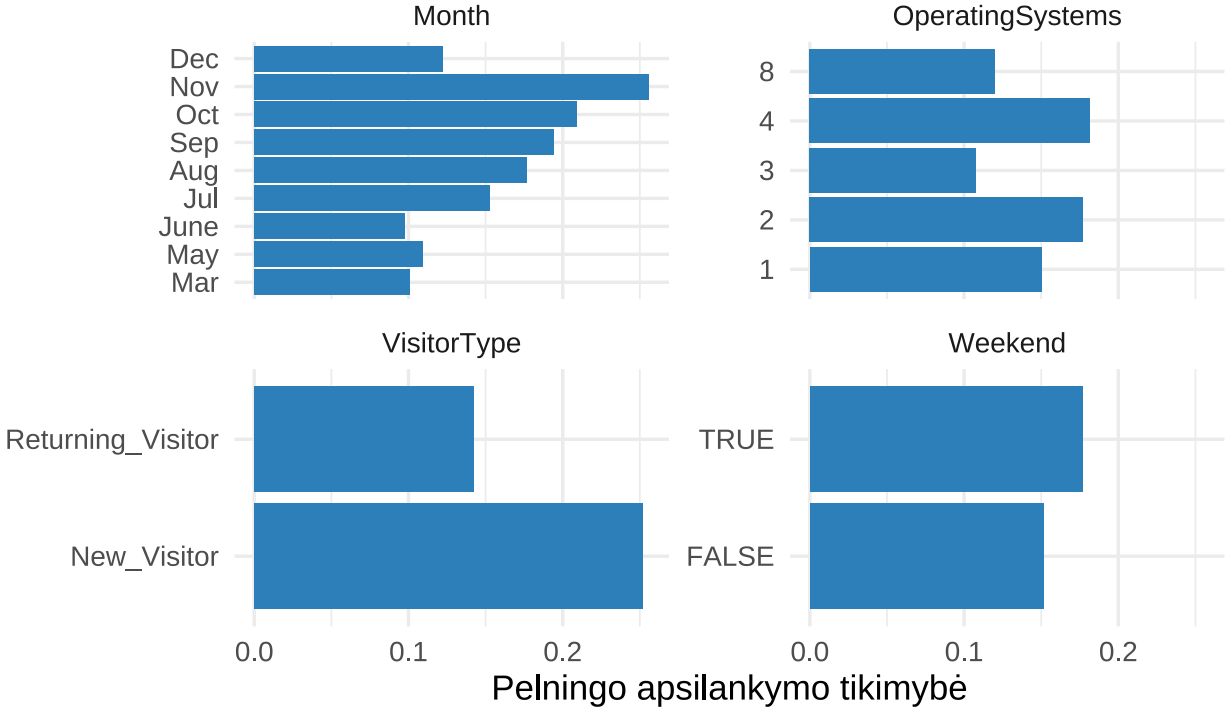

1 pav.: Pelningo apsilankymo santykinis dažnis pagal skirtingus sesiją apibūdinančius požymius

2 grafike iš kintamųjų „Administrative_Duration“, „Informational_Duration“ ir „ProductRelated_Duration“ smuiko formos ir stačiakampių grafikų matome, kad apsilankymo administraciniuose ir informaciniuose puslapiuose trukmė nedaro didelės įtakos užsakymo atlikimo tikimybei. Svarbu paminėti, kad grafike skalė logaritminė, taigi nedideli skirtumai grafike gali sąlygoti reikšmingus skirtumus pradiniuose duomenyse. Už

tat, sprendžiant pagal kvartilius, matome, kad laikas, praleistas produktų puslapiuose turėtų daryti didesnę įtaką užsakymo atlikimo tikimybei.

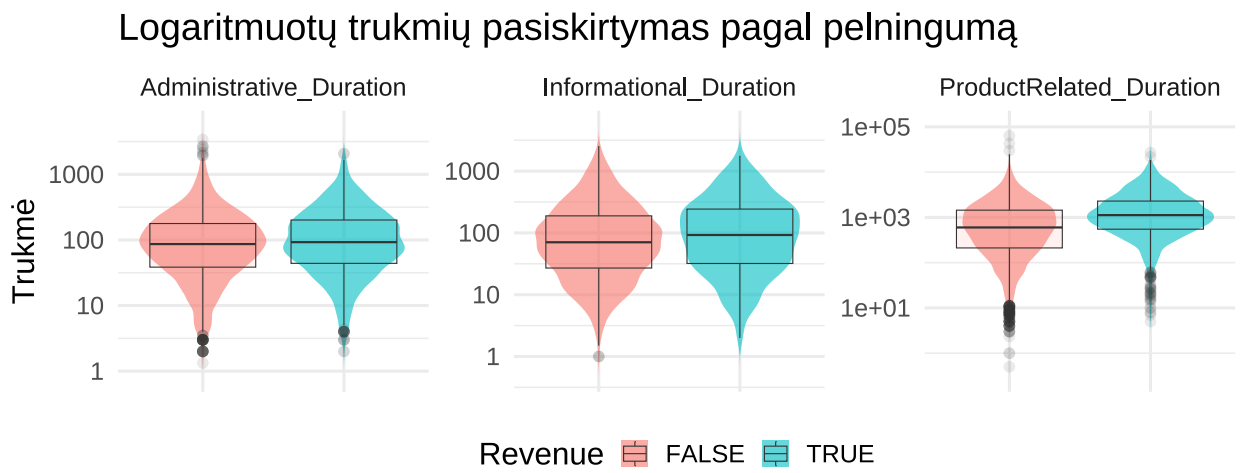

2 pav.: Sesijos trukmės požymių smuiko formos ir stačiakampės diagramos pagal pelningumą

„Google analytics“ metrikos, agreguotos kiekvienam aplankytam puslapiui sesijos metu, labiau įtakoja pasirinkimą atliksti užsakymą (žr. 3 pav.). „BounceRates“, kas yra dalis puslapių dalis, kuriuos naudotojai , neigiamai įtakoja pasirinkimą užsisakyti prekę iš parduotuvės. Taip pat neigiamai įtakoja ir „ExitRates“, kurį aprašėme duomenų aprašyme. Užtat vidutinis sesijos metu aplankytų puslapių „Google analytics“ įvertis („PageValues“) teigiamai įtakoja sesijos pelningumą.

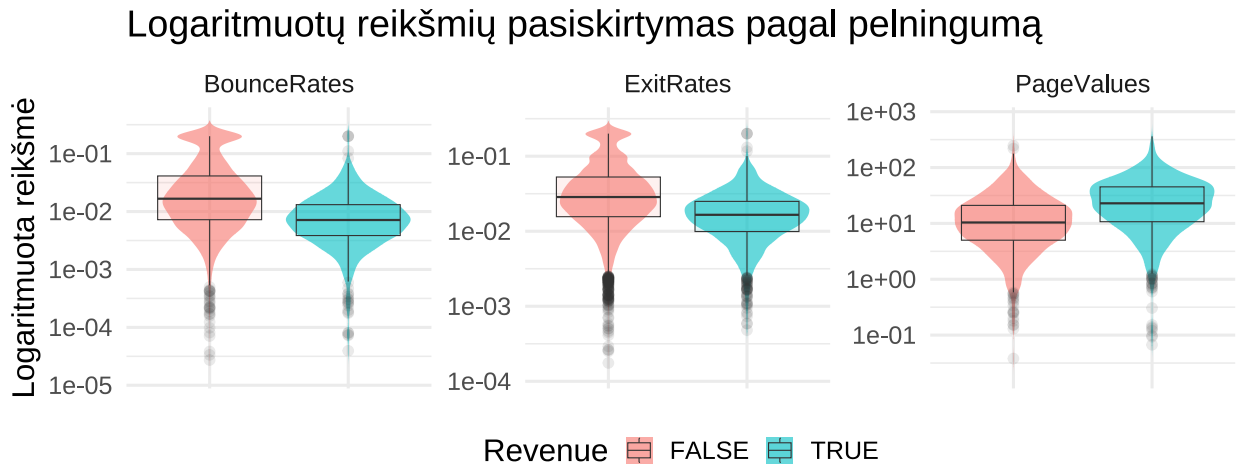

3 pav.: Sesijos metu aplankytų puslapių požymių smuiko formos ir stačiakampės diagramos pagal pelningumą

```
##
## FALSE  TRUE
##  8033  8033
```

2 Išskirtys

Išskirtis tikrinsime pasitelkę Kuko matą ir Pirsono liekanas.

Pavaizdavus Kuko matą (žr. 4 pav.), negalime pastebėti jokių išskirčių. Visos reikšmės neviršija 0,05.

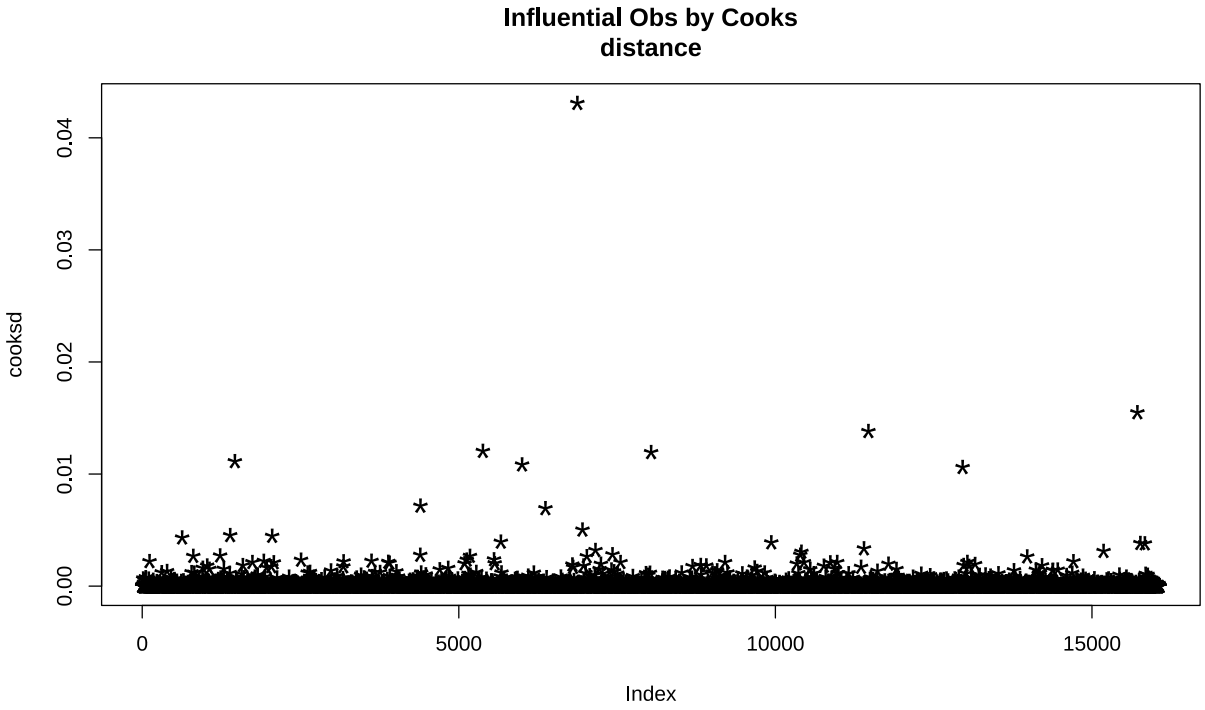

4 pav.: Kuko matas su logit modeliu

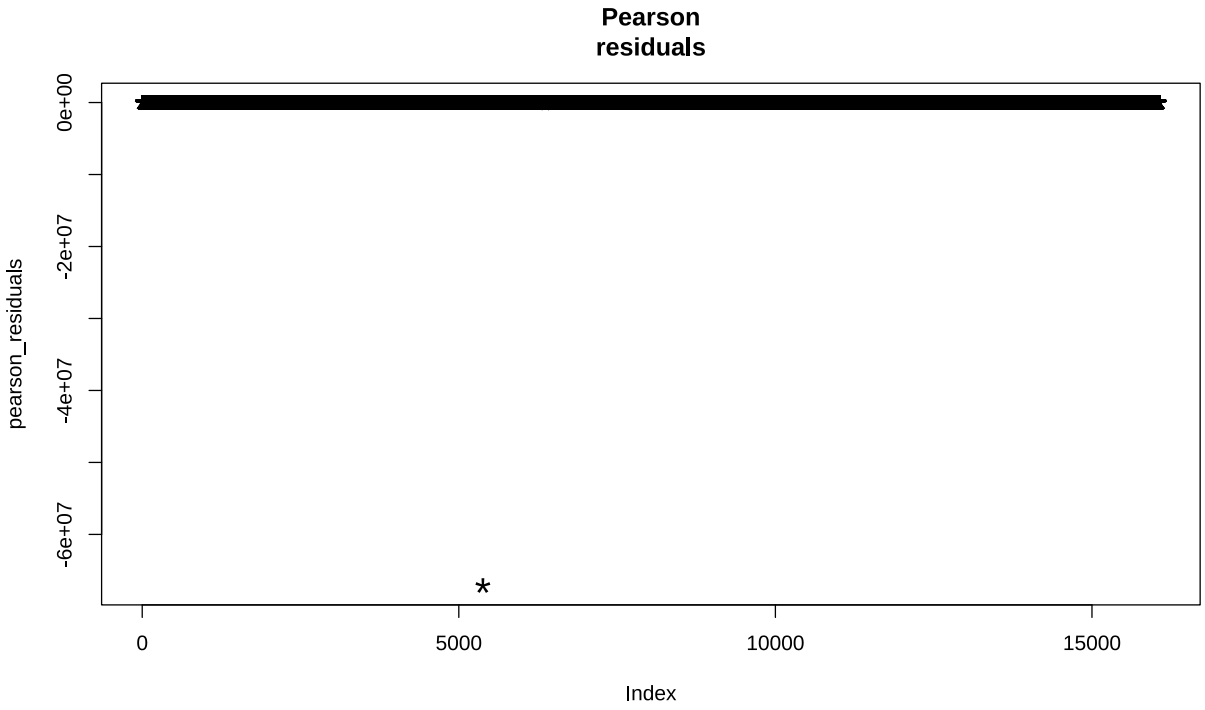

5 pav.: Prisono liekanos su logit modeliu

Ištyrę stebėjimus, kurių |Pirsono liekanos| > 3 (žr. 5 pav.), pastebėjome, kad kai kurie stebėjimai turi 0 praleisto laiko svetainėje. Taip pat turime atvejų, kai yra nurodytas konkretus praleistas laikas svetainėje, tačiau svetainių skaičius yra 0, todėl tokius stebėjimus pašalinsime. Kiti stebėjimai su didelėmis Pearsono liekanomis nebuvo pašalinti iš analizės, kadangi duomenų patikrinimo metu nebuvo pastebėta jokių akivaizdžių duomenų įvedimo ar matavimo klaidų. Todėl daroma prielaida, kad šios reikšmės atspindi realius duomenų svyravimus, o jų pašalinimas galėtų iškreipti analizės rezultatus.

A priedas

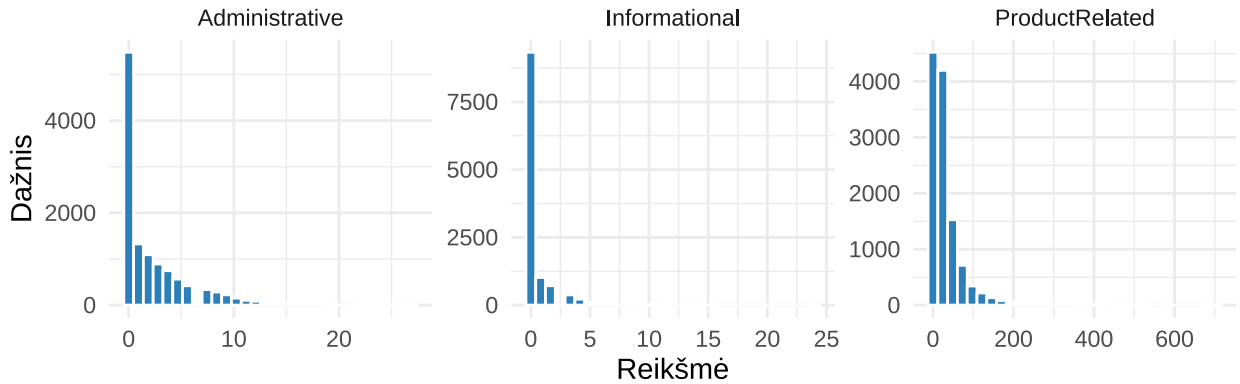

A.1 pav.: Sesijos metu aplankytų puslapių skaičiaus pasiskirtymas kiekviename puslapio tipui

A.1 lentelė: "VisitorType" ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
New_Visitor	1248	420	1668
Returning_Visitor	8793	1457	10250

A.2 lentelė: "Region" ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
1	3873	766	4639
2	916	184	1100
3	1978	346	2324
4	969	174	1143
5	254	52	306
6	678	112	790
7	633	118	751
8	365	56	421
9	375	69	444

A.3 lentelė: "Weekend" ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
FALSE	7742	1384	9126
TRUE	2299	493	2792

A.4 lentelė: “Month” ir pelningumo kryžminė lentelė

	Nepelninga	Pelninga	Bendrai
Mar	1692	190	1882
May	2952	362	3314
June	258	28	286
Jul	361	65	426
Aug	354	76	430
Sep	357	86	443
Oct	432	114	546
Nov	2194	755	2949
Dec	1441	201	1642

B priedas

2.1 DI naudojimas