



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

**Apsilankymo internetinėje parduotuvėje trukmės
prognozė, naudojant statistinius regresijos modelius**

Laboratorinis darbas

2 groupė 4 pogrupis
Nikita Demin, Lukas Janušauskas
Edvin Liubkevič, Martynas Zabitis

Vilnius
2026

Santrauka

Aktualumas

Nustatyti, kiek laiko naudotojas praleidžia internetinės parduotuvės svetainėje ir kokie faktoriai tai įtakoja, gali padėti nustatyti rinkodaros strategijas, nustatyti į ką atsižvelgti, norint prailginti šią trukmę. Taip pat, nustatę, kurie naudotojai tikėtinau praleis mažai laiko, galėsime nustatyti, kuriems naudotojams geriau pritaikyti kai kuriuos naudotojo sąsajos elementus (pvz. tokiems naudotojams naudoti greitesnius serverius).

Tikslas

Mūsų tikslas yra prognozuoti laiką, kurį naudotojai praleis svetainės puslapiuose.

Uždaviniai

Norint pasiekti savo užsibrėžto tikslo, išsikėlėme šiuos uždavinius:

1. Ištirti prie internetinės parduotuvės prisijungusių naudotojų sesijų charakteristikas, sąryšius su produktų puslapiuose praleista trukme.
2. Apmokyti ir optimizuoti statistinius regresijos modelius, skirtus prognozuoti su produktais susijusiuose puslapiuose praleistą trukmę.
3. Ištirti optimalaus modelio, prognozuojančio su produktais susijusiuose puslapiuose praleistą trukmę, požymių reikšmingumą, įtaką.

Lentelių sąrašas

1	Kiekybinių kintamųjų aprašymas	6
2	Kategorinių kintamųjų aprašymas	6
3	Kiekybinių kintamųjų skaitinės charakteristikos	7
4	Naršyklė dažnių lentelė	8
5	Srauto tipas dažnių lentelė	8
6	Spirmano koreliacijos su trukme apsilankymų produktų puslapiuose	9
7	B-splaino kryžminės validacijos rezultatai	11
8	Normalaus splaino kryžminės validacijos rezultatai	11
9	Glodžiojo splaino kryžminės validacijos rezultatai	12
10	Modelių išskirtys visame duomenų rinkinyje pagal Pirsono liekanų kriterijų	15
11	Modelių palyginimas testavimo aibėje	17
12	Kategorinių kintamųjų reikšmingumo lentelė	19
13	Kiekybinių kintamųjų reikšmingumo lentelė	20

Iliustracijų sąrašas

1	Skaidos diagramos, tarp kiekybinių kovariančių ir atsako - laiko, kurį naudotojas praleidžia internetinėje parduotuvėje	9
2	Stulpeliniai grafikai tarp kokybinių kovariančių ir laiko, praleisto produktų puslapiuose tiriamoje internetinėje parduotuvėje	10
3	RMSE priklausomybė nuo span ir PCA komponentų skaičiaus	14
4	Lokioji regresija: modelio tinkamumas prognozuojant bendrą laiką (sekundėmis), kurį lankytojas praleido parduodamų daiktų puslapiuose	14
5	B-splaino Kuko matas ir Pirsono liekanos	15
6	Natūralaus splaino Kuko matas ir Pirsono liekanos	16
7	Glodaus splaino Pirsono liekanos	16
8	Lokiosios regresijos Kuko matas ir Pirsono liekanos	17
9	GAM modelio daliniai efektai\label{fig:efektai}	18
10	GAM modelio prognozių tikslumas (prognozuotos ir tikrosios reikšmės)\label{fig:progn}	19

Turinys

Santrauka	2
1 Tyrimas	6
1.1 Duomenų aprašymas	6
1.2 Duomenų paruošimas	6
1.3 Duomenų pradinė analizė	7
2 Duomenų padalijimas	10
3 Spline modeliai	10
3.1 B-splainas	10
3.2 Natūralus splainas	11
3.3 Glodusis splainas	12
4 GAM modeliai	13
5 Lokalios regresijos modelis	13
5.1 Išskirtys	13
5.1.1 Modelio parinkimas	15
5.1.2 Požymių reikšmingumas	17
5.1.3 Interpretacija	17
5.1.4 Prognozė	17
6 Išvados	17
7 Šaltinių sąrašas	17
A priedas	19
7.1 DI naudojimas	20

1 Tyrimas

1.1 Duomenų aprašymas

Duomenys atsisiųsti iš *UCI Irvine Machine Learning Repository* (Sakar ir Kastro, 2018) su iš viso 10535 duomenų eilučių. Duomenų kintamieji aprašyti 1 ir 2 lentelėse. Duomenų rinkinį sudaro 1 metų informacija, kuri yra surinkta iš *columbia.com.tr* puslapio (Columbia, 2017).

1 lentelė: Kiekybinių kintamųjų aprašymas

Kintamojo pavadinimas	Kintamojo aprašymas
Administraciniai puslapiai	Kiek kartų lankytojas lankėsi paskyros valdymo puslapiuose.
Administracinių puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido paskyros valdymo puslapiuose.
Informaciniai puslapiai	Kiek kartų lankytojas lankėsi informaciniuose puslapiuose.
Informacinių puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido informaciniuose puslapiuose.
Produktų puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido parduodamų daiktų puslapiuose.
Atšokimo dažnis	Vidutinis lankytojo aplankytų puslapių skaičius, prieš pabaigiant sesiją, kai aplankyta tik viena prekė.
Išėjimo dažnis	Vidutinis lankytojo aplankytų puslapių skaičius, prieš pabaigiant sesiją, kai aplankyta daugiau nei viena prekė.
Puslapio vertė	Vidutinė lankytojo aplankytų puslapių vertė.
Ypatinga diena	Svetainės apsilankymo laiko artumas ypatingai dienai (pvz., šventei, išpardavimui).

2 lentelė: Kategorinių kintamųjų aprašymas

Kintamojo pavadinimas	Kintamojo aprašymas
Operacinė sistema	Lankytojo operacinė sistema.
Naršyklė	Lankytojo interneto naršyklė.
Regionas	Geografinis regionas, iš kurio lankytojas pradėjo sesiją.
Srauto tipas	Šaltinis, iš kurio lankytojas atvyko į svetainę (pvz., reklama kitame puslapyje, SMS, tiesioginis).
Lankytojo tipas	Lankytojo tipas: „Naujas lankytojas“, „Sugrįžtantis lankytojas“ ir „Kitas“
Savaitgalis	Ar apsilankymo data sutampa su savaitgalio.
Mėnuo	Apsilankymo datos mėnuo.
Pelningumas	Ar sesija buvo pelninga.

1.2 Duomenų paruošimas

Kintamieji „Operacinė sistema“, „Naršyklė“, „Regionas“ ir „Srauto tipas“ yra kategoriniai kintamieji, užkoduoti natūraliais skaičiais. Todėl juos pakeičiame atitinkamais faktoriais ir vėliau iš jų formuosime fiktyvius kintamuosius. Kintamasis „SpecialDay“, sprendžiant pagal reikšmes ir aprašymą yra ranginis kitamasis įgaunantis 6 skirtingas reikšmes: $\{0; 0, 2; \dots; 1\}$.

Duomenų aprašyme autoriai teigia, kad praleistų reikšmių nėra. Mes pasitiksliname, pasileidę atitinkamą R kodą - praleistų reikšmių nėra.

Loginių išskirčių tyrimas yra būtina dalis tyrimo, kadangi kai kurios iš duomenų rinkinyje esančios sesijos gali būti informacijos surinkimo robotai (*angl. web-scrapers*). Kad ištirtume logines išskirtis sudarėme skaitinių charakteristikų lentelę kiekybiniam kintamiesiems (3 lentelė). Joje naudojami standartiniai skaitinių charakteristikų žymėjimai: Min - minimumas, Q_n - n -tasis kvartilis, μ - vidurkis, Max - maksimumas. 3 lentelėje matome, jog nėra jokių nelogiškai išsiskiriančių reikšmių kintamuosiuose nesusijusiuose su apsilankymo trukme. Tačiau pastebėjome, kad kintamieji, susijusiems su sesijos trukme, turi loginių išskirčių, kurių tvarkybą pakomentuosim sekančiame paragrafe.

3 lentelė: Kiekybinių kintamųjų skaitinės charakteristikos

Kintamasis	Min	Q_1	Q_2	μ	Q_3	Max
Administraciniai puslapiai	0	0,00	1,00	2,32	4,00	27,00
Laikas administraciniuose puslapiuose	0	0,00	7,50	80,82	93,26	3398,75
Informaciniai puslapiai	0	0,00	0,00	0,50	0,00	24,00
Laikas informaciniuose puslapiuose	0	0,00	0,00	34,47	0,00	2549,38
Produktų puslapių trukmė	0	184,14	598,94	1194,75	1464,16	63973,52
Atšokimo dažnis	0	0,00	0,00	0,02	0,02	0,20
Išėjimo dažnis	0	0,01	0,03	0,04	0,05	0,20
Puslapio vertė	0	0,00	0,00	5,89	0,00	361,76
Ypatinga diena	0	0,00	0,00	0,06	0,00	1,00

Kad susitvarkytume su išskirtimis, išimsime stebėjimus, kai bendras praleistas laikas svetainėse yra nulis. Taip pat, pašalinsime stebėjimus, jei laikas tam tikram svetainių tipui yra nenulinis (pvz. nurodyta, kad administraciniuose puslapiuose praleistas tam tikras laikas), tačiau to tipo puslapių nebuvo aplankyta.

1.3 Duomenų pradinė analizė

Prieš apmokant regresijos modelius labai svarbu įsitikinti, kad kategorinio kintamojo lygmenų kartotinumai yra pakankamai dideli, nes lygmenims, turintiems mažai stebėjimų, negalėsime daryti išvadų. Toliau pašaliname kategorinių kintamųjų lygmenis, turinčius 5 ar mažiau stebėjimų.

Iš žemiau pateiktų lentelių, matome, kad yra probleminių faktorių lygmenų. „Naršyklės” devintas lygmuo, turi mažiau nei 5 stebėjimus. Tuo tarpu faktorius „Srauto tipas” turi tris probleminius lygmenis, kuriuos mes išimsime: būtent 12-as, 16-as ir 17-as. Šių faktorių dažnių lentelės pateiktos atitinkamai 4 ir 5 lentelėse.

4 lentelė: Naršyklė dažnių lentelė


Naršyklė	Dažnis	Santykinis dažnis (%)
1	2204	19.6
2	7323	65.0
3	94	0.8
4	672	6.0
5	430	3.8
6	161	1.4
7	44	0.4
8	120	1.1
9	1	0.0
10	156	1.4
11	6	0.1
12	10	0.1
13	49	0.4

5 lentelė: Srauto tipas dažnių lentelė

Srauto tipas	Dažnis	Santykinis dažnis (%)
1	2143	19.0
2	3725	33.1
3	1829	16.2
4	1000	8.9
5	249	2.2
6	402	3.6
7	37	0.3
8	325	2.9
9	36	0.3
10	413	3.7
11	230	2.0
12	1	0.0
13	637	5.7
14	13	0.1
15	28	0.2
16	3	0.0
17	1	0.0
18	8	0.1
19	16	0.1
20	174	1.5

Toliau tiriamie kiekybinių požymių sąryšius su atsaku - laiku, praleistu produktų puslapiuose. Sąryšius tiriamie, pasitelkę sklaidos diagramų groteles (žr. 1 pav.), kurių x ir y ašims pritaikyta logaritminė transformacija. Pastebime, kad turime tam tikrą koreliaciją su visomis potencialiomis kovariantėmis išskyrus kintamąjį „Ypatinga diena“. Aplankytų administracinių, informacinių ir produktų puslapių skaičius natūraliai reiškia didesnę trukmę, praleistą produktų puslapiuose, taigi pastebime teigiamą koreliaciją. Neigiamą puslapių kokybę atskleidžiančios „Google Analytics“ metrikos „Atšokimo dažnis ir Išėjimo dažnis“ turi neigiamą koreliaciją su. Kas irgi yra akivaizdu - kuo naudotojo aplankyti puslapiai yra labiau linkę būti sesijos pabaigimo priežastimi ar būti praversti nesukūrus jokios užklauso puslapyje, tuo puslapiai yra labiau linkę skatinti naudotoją atsijungti nuo internetinės parduotuvės. Tuo tarpu puslapio Google Analytics vertė turi neigiamą koreliaciją su atsaku, kas nėra intuityvu. Tai galimai yra konkurentų puslapiai, turintys aukštus įvertinimus ar kita problema, į kurią reikėtų iš dalikinės pasižiūrėti.

Šias išvadas patvirtina ir 6 lentelė.



1 pav.: Sklaidos diagramos, tarp kiekybinių kovariančių ir atsako - laiko, kurį naudotojas praleidžia internetinėje parduotuvėje


6 lentelė: Spirmano koreliacijos su trukme apsilankymų produktų puslapiuose

Kintamasis	Spearmano koeficientas
Administraciniai puslapiai	0.370
Laikas administraciniuose puslapiuose	0.36
Informaciniai puslapiai	0.352
Laikas informaciniuose puslapiuose	0.35
Atšokimo dažnis	0.106
Išėjimo dažnis	-0.375
Puslapio vertė	0.339
Ypatinga diena	-0.052

Iš stulpelinių grafikų, su 95 % procentilinių savirankos intervalais, (žr. 2 pav.) pastebime, kad:

1. Lankytojo tipas, mėnuo, kurio metu fiksuota naudotojo sesija, naudotojo naršyklė ir naudojama operacinė sistema turi reikšmingai skirtingus vidurkius praleisto laiko produktų puslapiuose.
2. Laikas, praleistas produktų puslapiuose vidutiniškai nepriklauso nuo to, ar sesija fiksuota savaitgalį, ar ne.

- Tik pavieniai regionai išsiskiria laiko, praleisto produktų puslapiuose prasme, tačiau bendrai paėmus labai panašus atsako vidurkis visuose lygmenyse.



2 pav.: Stulpeliniai grafikai tarp kokybinių kovariančių ir laiko, praleisto produktų puslapiuose tiriamoje internetinėje parduotuvėje

2 Duomenų padalijimas


3 Spline modeliai

3.1 B-splainas

B-splaino modeliui turėjome parinkti vieną optimalią kovariantę ir mazgų skaičių su kuriuo gauname mažiausią RSME. Geriausios kovariantės ieškojimui naudojame visus stulpelius išskyrus patį „ProductRelated_Duration“, kurį norime prognozuoti ir atmetus produktų puslapių peržiūrų skaičių, kadangi ši viena kovariantė per daug gerai įvertina praleistą laiką produktų puslapiuose. Mazgų galimas rėžis buvo nuo 3 iki 15, atkreipiant dėmesį, kad didelis mazgų skaičius gali reikšti modelio per didelį prisitaikymą prie duomenų (angl. over-fitting). Kaip matome \ref{tab:bspline_rmse} lentelėje, mažiausią RMSE gavome su „Administrative_Duration“ kovariante ir 8 mazgais, o prasčiausiai naudojant B-splaino modelį gauti rezultatai su specialios dienos kintamuoju. Taip pat, geri rezultatai gauti su „BounceRates“ kovariante.

7 lentelė: B-splaino kryžminės validacijos rezultatai

Kintamasis	Mazgų skaičius	RMSE
Administracinių puslapių trukmė	8	1729,83
Atšokimo dažnis	10	1793,04
Informacinių puslapių trukmė	7	1824,94
Administraciniai puslapiai	3	1850,24
Puslapio vertė	15	1863,10
Informaciniai puslapiai	6	1885,17
Išėjimo dažnis	4	1925,19
Ypatinga diena	5	1983,38



3.2 Natūralus splainas


Natūralus splainas turi tam tikras taisykles, dėl kurių šio splaino modelio kraštai yra tiesiški. ? Kaip ir b-splaino modelio atveju, mes ieškome tokios kovariantės ir mazgų skaičiaus, kad gautume mažiausią RSME. 8 lentelės rezultatai rodo, kad mažiausias RSME gautas su „BounceRates“ ir 8 mazgais. Skirtingai nei 7 lentelėje, kur geriausi rezultatai gauti su administracinių puslapių peržiūros laiku, su natūralių splainų modeliu šių puslapių peržiūrų laikas yra tik penktoje vietoje iš aštuonių. Prasčiausi rezultatai vėl gauti su specialiųjų dienų kintamuoju.

8 lentelė: Normalaus splaino kryžminės validacijos rezultatai

Kintamasis	Mazgų skaičius	RMSE
Atšokimo dažnis	8	1776,37
Administraciniai puslapiai	3	1827,95
Informaciniai puslapiai	8	1838,42
Puslapio vertė	13	1845,38
Administracinių puslapių trukmė	15	1847,63
Informacinių puslapių trukmė	15	1861,16

Kintamasis	Mazgų skaičius	RMSE
Išėjimo dažnis	15	1904,78
Ypatinga diena	10	1964,96

B-splaino modelio gerumo patikrinimas




3.3 Glodusis splainas

Skirtingai nei b-splainai, kurie reguliuoja splainą pagal konkretų mazgų skaičių, glodieji splainai mazgus išdėsto kiekviename unikaliame duomenų stebėjime, o modelio sudėtingumą valdo per regularizavimo (λ) parametą. Šį kart geriausiai rezultatai gauti su „Administrative_Duration“ kintamuoju ir $\lambda = 0.0085$ reikšme (žr. 9 lentelę).

9 lentelė: Glodžiojo splaino kryžminės validacijos rezultatai

Kintamasis	Mazgų skaičius	Lambda	RMSE
Administracinių puslapių trukmė	3	0,0085	1742,072
Atšokimo dažnis	3	<0,001	1793,220
Administraciniai puslapiai	3	0,6210	1838,506
Išėjimo dažnis	3	<0,001	1913,889
Informaciniai puslapiai	3	<0,001	NA
Informacinių puslapių trukmė	3	<0,001	NA
Puslapio vertė	3	<0,001	NA
Ypatinga diena	3	<0,001	NA

Glodaus spline modelio gerumo patikrinimas



4 GAM modeliai

Pirmame GAM modelyje kiekvienam skaitiniam kintamajam taikomi glodinantys splainai, o konkrečiai – thin plate regression splines. Tai yra numatytasis splainų tipas, naudojamas mgcv pakete. Šie splainai pasižymi tuo, kad nereikalauja iš anksto parinkti mazgų (angl. knots) vietų – jų forma automatiškai nustatoma iš duomenų.

Antru atveju sudaromas modelis, kuriame naudojami du skirtingi netiesinių ryšių modeliavimui skirti metodai. Daliai kintamųjų taikomi regresiniai splainai, kurių sudėtingumas yra nustatomas iš anksto per laisvės laipsnių parametą. Kitai kintamųjų daliai taikoma lokali regresija.

5 Lokali regresijos modelis


Lokali regresijos modelis sudarytas dviem etapais. Siekiant padidinti modelio našumą ir išvengti kintamųjų pertekliaus, skaitiniai kintamieji pirmiausia standartizuoti, o jų dimensiškumas sumažintas taikant pagrindinių komponentių analizę (*PCA*)

Optimali hiperparametrų kombinacija – pagrindinių komponentių skaičius (nuo 1 iki 4) ir glodinimo parametras (nuo 0,1 iki 0,9 su 0,1 žingsniu) – parinkta naudojant kryžminį patikrinimą (angl. *cross-validation*), minimizuojant vidutinę kvadratinę paklaidą (RMSE) (žr. 4 pav.). Tiksliausi rezultatai gauti modelio konfigūracijoje naudojant dvi pagrindines komponentes ir 0,9 glodinimo parametą.


5.1 Išskirtys

Išskirtis tikrinsime pasitelkę Kuko matą (angl. *Cook's distance*) ir Pirsono liekanas (angl. *Pearson residuals*). Kad identifikuotume potencialias išskirtis, tiriant Kuko matą D_i naudosime vieną iš empirinių taisyklių $D_i < 1$, t.y. stebėjamą žymėsime kaip išskirtį, jei Kuko matas didesnis už 1 (*Tiesinių modelių kurso medžiaga*, 2025). Tuo tarpu, Pirsono liekanoms taikysime empirinę taisyklę: $|Pirsono\ liekana| > 3$.

Pavaizdavus Kuko matą (žr. ?? pav.), išskirtis pastebime tik b-splaino modelyje, kurios yra arti dvejetainio, kas yra daugiau už mūsų naudotą ribą. Tačiau šių išskirčių nepastebime kituose modeliuose.



3 pav.: RMSE priklausomybė nuo span ir PCA komponentių skaičiaus




4 pav.: Lokaloji regresija: modelio tinkamumas prognozuojant bendrą laiką (sekundėmis), kurį lankytojas praleido parduodamų daiktų puslapiuose

Ištirus stebėjimus, kurių $|Pirsono\ liekana| > 3$, pastebėjome gana panašų skaičių išskirčių kiekvienam modeliui (žr. 10 lentelę), atsižvelgus į stebėjimų skaičių išskirtys sudaro vos 1,5 - 2 %. Tirdami išskirtis nepastebėjome jokių akivaizdžių duomenų įvedimo ar matavimo klaidų ir dėl jų pakankamai mažo kiekio jas pašalinsime.

10 lentelė: Modelių išskirtys visame duomenų rinkinyje pagal Pirsono liekanų kriterijų

Modelis	Išskirtys	Dalis
B-splainas	231	2,05 %
Naturalusis splainas	171	1,52 %
Glodusis splainas	189	1,68 %
Lokatioji regresija	226	2,01 %
GAM	206	1,83 %




5 pav.: B-splaino Kuko matas ir Pirsono liekanos

Kadangi išskirčių nėra daug ir jos nėra tendencingos mes jas išimsime ir toliau modeliai bus tikrinami be jų.


5.1.1 Modelio parinkimas

Pagal prasmę, manome, kad neigiamos „Google analytics“ metrikas sudauginti būtų prasminga, nes taip kombinuojame du aspektus prastos puslapių kokybės: išėjimo nepaspaudus nieko, sesijos pabaigimo dėl to puslapio.


Apmokytus modelius su sąveikomis palyginame kartu su pradiniais modeliais (splainų, lokalsiosios regresijos ir adityviaisiais modeliais) 11 lentelėje.



6 pav.: Naturalaus splaino Kuko matas ir Pirsono liekanos



7 pav.: Glodaus splaino Pirsono liekanos



8 pav.: Lokaliosios regresijos Kuko matas ir Pirsono liekanos

11 lentelė: Modelių palyginimas testavimo aibėje

Modelis	RMSE	R ²	MAE	SMAPE
B-splainas	1681.91	0.4096	1027.80	88.77
Naturalusis splainas	1992.47	0.1714	945.18	82.58
Glodusis splainas	2296.35	-0.1006	1395.30	100.83
GAM	1443.13	0.5653	849.31	81.67
Lokalioji regresija	2378.90	-0.2016	1267.40	96.60

Lentelėje 11 pateiktos modelio tikslumo metrikos, tarp kurių yra SMAPE lygus $\text{sMAPE} = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \times 100$.

Matome, kad glodžiojo splaino ir lokalioji regresija yra prastesnės už vidurkį, kadangi jų R^2 įvertis yra mažesnis už nulį. Toliau pastebime, kad kiti splaino modeliai yra nelabai tikslūs, kadangi jų R^2 reikšmės yra nedidelės, MAE ir SMAPE yra didesnės.

Galiausiai, GAM modelis yra geriausia, turintis patį didžiausią R^2 siekiantį virš 0,56. Taigi toliau tirsime tik GAM modelį.

5.1.2 Požymių reikšmingumas


Toliau tyrėme požymių reikšmingumą, tam naudojome lentelę, pateiktą A priede. Pastebime, kad kiekviena kovariantė yra reikšminga, taigi mes negalime išimti kintamųjų.

5.1.3 Interpretacija


Iš grafikų matome (žr. ?? pav.), kad didžiausią įtaką daro aplankytų administracinių puslapių skaičius, informacinių puslapių skaičius ir juose praleistas laikas. Kiti faktoriai daro kelis kartus mažesnę įtaką.

5.1.4 Prognozė

Matome iš 4 pav., kad sklaida taškų aplink tiesę, reprezentuojančią tikrų ir prognozuojamų taškų lygybę, didėja didėjant atsako reikšmėms. Taip pat didžiausias atitrūkimas nuo šios tiesės yra ties didžiausiomis atsako reikšmėmis. Taigi, taisant toliau šį modelį reikia turėti omenyje didžiausias atsako reikšmes.



9 pav.: GAM modelio daliniai efektai\label{fig:efektai}



10 pav.: GAM modelio prognozių tikslumas (prognozuotos ir tikrosios reikšmės)

A priedas

12 lentelė: Kategorinių kintamųjų reikšmingumo lentelė

	t statistika	p reikšmė
(Intercept)	10.4942	<0.001
MonthDec	-1.3068	0.1913
MonthFeb	-1.7295	0.0837
MonthJul	-0.7518	0.4522
MonthJune	0.5689	0.5695
MonthMay	-2.1475	0.0318
MonthMar	-3.7800	<0.001
MonthNov	4.3938	<0.001
MonthOct	-3.1788	0.0015
MonthSep	-1.3560	0.1751
TrafficType2	-4.0192	<0.001
TrafficType3	-5.7838	<0.001
TrafficType4	-6.1552	<0.001
TrafficType5	-5.2367	<0.001
TrafficType6	-1.7906	0.0734
TrafficType7	-2.6704	0.0076
TrafficType8	-3.7035	<0.001
TrafficType9	-1.5054	0.1323
TrafficType10	-2.2350	0.0254
TrafficType11	-3.3057	<0.001
TrafficType13	-0.2057	0.8370
TrafficType14	-0.5496	0.5826

	t statistika	p reikšmė
TrafficType15	-1.4616	0.1439
TrafficType18	-1.0490	0.2942
TrafficType19	0.4034	0.6867
TrafficType20	-3.7151	<0.001
SpecialDay	2.5590	0.0105
VisitorTypeOther	1.7085	0.0876
VisitorTypeReturning_Visitor	10.4142	<0.001
WeekendTRUE	-2.0653	0.0389

13 lentelė: Kiekybinių kintamųjų reikšmingumo lentelė

	t statistika	p reikšmė
Administrative	53.8452	<0.001
Administrative_Duration	75.7616	<0.001
Informational	22.0907	<0.001
Informational_Duration	16.6197	<0.001
PageValues	11.9487	<0.001
BounceRates	34.6706	<0.001
ExitRates	31.9849	<0.001

7.1 DI naudojimas

Naudotas „Google Gemini 3 Flash Preview“, kad patikrinti ar surašyti uždaviniai nėra etapai. Taip pat lentelėse, grafikuose pakeisti taškus į kablelius, kad būtų lietuviškas formatavimas.

Naudotas „Claude“ ieškant *R* funkcijų atitikmenų *Python* kalboje bei braižant grafikus, surašant lenteles ir *R* aplinkoje.

„ChatGPT“ skirtas gramatinėms klaidoms taisyti, *R Markdown* specifinių klaidų taisymui, rečiau naudojamų *R* paketų naudojimui.