



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

**Apsilankymo internetinėje parduotuvėje trukmės
prognozė, naudojant statistinius regresijos modelius**

Laboratorinis darbas

2 groupė 4 pogrupis
Nikita Demin, Lukas Janušauskas
Edvin Liubkevič, Martynas Zabitis

Vilnius
2026

Santrauka

Aktualumas

Nustatyti, ar

Tikslas

Mūsų tikslas yra prognozuoti laiką, kurį naudotojai praleis svetainės puslapiuose

Uždaviniai

Norint pasiekti savo užsibrėžto tikslo, išsikėlėme šiuos uždavinius:

1. Ištirti prie internetinės parduotuvės prisijungusių naudotojų sesijų charakteristikas, sąryšius su produktų puslapiuose praleista trukme.
2. Apmokyti ir optimizuoti statistinius regresijos modelius, skirtus prognozuoti su produktais susijusiuose puslapiuose praleistą trukmę.
3. Ištirti optimalaus modelio, prognozuojančio su produktais susijusiuose puslapiuose praleistą trukmę, požymių reikšmingumą, įtaką.

Lentelių sąrašas

1	Kiekybinių kintamųjų aprašymas	6
2	Kategorinių kintamųjų aprašymas	6
3	Kiekybinių kintamųjų skaitinės charakteristikos	7
4	Naršyklė dažnių lentelė	8
5	Srauto tipas dažnių lentelė	8
6	Spirmano koreliacijos su trukme apsilankymų produktų puslapiuose	9

Iliustracijų sąrašas

Turinys

Santrauka	2
1 Tyrimas	6
1.1 Duomenų aprašymas	6
1.2 Duomenų paruošimas	6
1.3 Duomenų pradinė analizė	7
2 Šaltinių sąrašas	10
A priedas	11
2.1 DI naudojimas	11

1 Tyrimas

1.1 Duomenų aprašymas

Duomenys atsisiųsti iš *UCI Irvine Machine Learning Repository* (Sakar ir Kastro, 2018) su iš viso 10535 duomenų eilučių. Duomenų kintamieji aprašyti 1 ir 2 lentelėse. Duomenų rinkinį sudaro 1 metų informacija, kuri yra surinkta iš *columbia.com.tr* puslapio (*Columbia*, 2017).

1 lentelė: Kiekybinių kintamųjų aprašymas

Kintamojo pavadinimas	Kintamojo aprašymas
Administraciniai puslapiai	Kiek kartų lankytojas lankėsi paskyros valdymo puslapiuose.
Administracinių puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido paskyros valdymo puslapiuose.
Informaciniai puslapiai	Kiek kartų lankytojas lankėsi informaciniuose puslapiuose.
Informacinių puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido informaciniuose puslapiuose.
Produktų puslapiai	Kiek kartų lankytojas lankėsi parduodamų daiktų puslapiuose.
Produktų puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido parduodamų daiktų puslapiuose.
Atšokimo dažnis	Vidutinis lankytojo aplankytų puslapių skaičius, prieš pabaigiant sesiją, kai aplankyta tik viena prekė.
Išėjimo dažnis	Vidutinis lankytojo aplankytų puslapių skaičius, prieš pabaigiant sesiją, kai aplankyta daugiau nei viena prekė.
Puslapio vertė	Vidutinė lankytojo aplankytų puslapių vertė.
Ypatinga diena	Svetainės apsilankymo laiko artumas ypatingai dienai (pvz., šventei, išpardavimui).

2 lentelė: Kategorinių kintamųjų aprašymas

Kintamojo pavadinimas	Kintamojo aprašymas
Operacinė sistema	Lankytojo operacinė sistema.
Naršyklė	Lankytojo interneto naršyklė.
Regionas	Geografinis regionas, iš kurio lankytojas pradėjo sesiją.
Srauto tipas	Šaltinis, iš kurio lankytojas atvyko į svetainę (pvz., reklama kitame puslapyje, SMS, tiesioginis).
Lankytojo tipas	Lankytojo tipas: „Naujas lankytojas“, „Sugrįžtantis lankytojas“ ir „Kitas“
Savaitgalis	Ar apsilankymo data sutampa su savaitgaliu.
Mėnuo	Apsilankymo datos mėnuo.
Pelningumas	Ar sesija buvo pelninga.

1.2 Duomenų paruošimas

Kintamieji „OperatingSystems“, „Browser“, „Region“, „TrafficType“ yra kategoriniai kintamieji, užkoduoti natūraliais skaičiais. Todėl juos pakeičiame atitinkamais faktoriais ir vėliau iš jų formuosime fiktyvius kintamuosius. Kintamasis „SpecialDay“, sprendžiant pagal reikšmes ir aprašymą yra ranginis kitamasis įgaunantis 6 skirtingas reikšmes: {0; 0, 2; ...; 1}.

Duomenų aprašyme autoriai teigia, kad praleistų reikšmių nėra. Mes pasitiksliname, pasileidę atitinkamą R kodą - praleistų reikšmių nėra.

Loginių išskirčių tyrimas yra būtina dalis tyrimo, kadangi kai kurios iš duomenų rinkinyje esančios sesijos gali būti informacijos surinkimo robotai (*angl. web-scrapers*). Kad ištirtume logines išskirtis sudarėme skaitinių charakteristikų lentelę kiekybiniais kintamiesiems (3 lentelė). Joje naudojami standartiniai skaitinių charakteristikų žymėjimai: Min - minimumas, Q_n - n -tasis kvartilis, μ - vidurkis, Max - maximumas. 3 lentelėje matome, jog nėra jokių nelogiškai išsiskiriančių reikšmių kintamuosiuose nesusijusiuose su apsilankymo trukme. Tačiau kintamiesiems, susijusiems su bendra apsilankymo trukme

3 lentelė: Kiekybinių kintamųjų skaitinės charakteristikos

Kintamasis	Min	Q_1	Q_2	μ	Q_3	Max
Administraciniai puslapiai	0	0,00	1,00	2,32	4,00	27,00
Laikas administraciniuose puslapiuose	0	0,00	7,50	80,82	93,26	3398,75
Informaciniai puslapiai	0	0,00	0,00	0,50	0,00	24,00
Laikas informaciniuose puslapiuose	0	0,00	0,00	34,47	0,00	2549,38
Produktų puslapiai	0	7,00	18,00	31,73	38,00	705,00
Produktų puslapių trukmė	0	184,14	598,94	1194,75	1464,16	63973,52
Atšokimo dažnis	0	0,00	0,00	0,02	0,02	0,20
Išėjimo dažnis	0	0,01	0,03	0,04	0,05	0,20
Puslapio vertė	0	0,00	0,00	5,89	0,00	361,76
Ypatinga diena	0	0,00	0,00	0,06	0,00	1,00

Kad susitvarkytume su išskirtimis, išimsime stebėjimus, kai bendras praleistas laikas svetainėse yra nulis. Taip pat, pašalinsime stebėjimus, jei laikas tam tikram svetainių tipui yra nenulinis (pvz. nurodyta, kad administraciniuose puslapiuose praleistas tam tikras laikas), tačiau to tipo puslapių nebuvo aplankyta.

1.3 Duomenų pradinė analizė

Šioje aprašymo dalyje pateikiame tik svarbiausius akcentus, kurie mums bus svarbus, kitus grafikus, išbrėžtus duomenų pradinei tyrybai, pateiksime A priede.

Prieš taikant binarinę regresiją labai svarbu įsitikinti, kad kategorinio kintamojo lygmenų kartotinumai yra pakankamai dideli, esant visoms klasifikuojamo kintamojo reikšmėms.

Iš žemiau pateiktų lentelių, matome, kad yra probleminių faktorių lygmenų. Kintamasis „VisitorType“ turi lygmenį „Other“, kuris gali būti problemiškas, padarius dominuojančios klasės sumažinimą, taigi šį faktoriaus lygmenį pašalinsime.


Pašalinsime „OperatingSystems“, „Browser“ faktorių lygmenis, kurie turi mažiau arba lygiai 5 stebėjimus, esant pelningai sesijai. Faktorių „TrafficType“ turi daug probleminių lygmenų, taigi juos šalinant išmesime daug duomenų, todėl mes šį faktorių pašalinsime. Šių trijų minėtų faktorių dažnių lentelės pateiktos atitinkamai ??, 4 ir 5 lentelėse. Taip pat kintamojo „Month“ lygmuo „Feb“ (atitinkantis vasario mėnesį) turi tik tris stebėjimus, taigi pašalinsime ir vasario mėnesio stebėjimus. Kitos kryžminės dažnių lentelės pateiktos priede A.

4 lentelė: Naršyklė dažnių lentelė

Naršyklė	Dažnis	Santykinis dažnis (%)
1	2196	19.5
2	7318	65.0
3	94	0.8
4	672	6.0
5	430	3.8
6	160	1.4
7	44	0.4
8	119	1.1
9	1	0.0
10	156	1.4
11	6	0.1
12	10	0.1
13	49	0.4


5 lentelė: Srauto tipas dažnių lentelė

Srauto tipas	Dažnis	Santykinis dažnis (%)
1	2143	19.0
2	3722	33.1
3	1825	16.2
4	1000	8.9
5	246	2.2
6	401	3.6
7	37	0.3
8	323	2.9
9	36	0.3
10	412	3.7
11	230	2.0
12	1	0.0
13	636	5.7
14	13	0.1
15	28	0.2
16	3	0.0
17	1	0.0
18	8	0.1
19	16	0.1
20	174	1.5



6 lentelė: Spirmano koreliacijos su trukme apsilankymų produktų puslapiuose

Kintamasis	Spearmano koeficientas
Administraciniai puslapiai	0.371
Laikas administraciniuose puslapiuose	0.36
Informaciniai puslapiai	0.353
Laikas informaciniuose puslapiuose	0.35
Produktų puslapiai	0.860
Atšokimo dažnis	0.107
Išėjimo dažnis	-0.373
Puslapio vertė	0.338
Ypatinga diena	-0.053



2 Šaltinių sąrašas

Columbia (2017). Adresas: <https://www.columbia.com.tr/>.

Regresinės analizės kurso medžiaga (2026). Adresas: <https://emokymai.vu.lt/course/view.php?id=8011>.

Sakar, C. ir Kastro, Y. (2018) „Online Shoppers Purchasing Intention Dataset“. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5F88Q>.

Tiesinių modelių kurso medžiaga (2025). Adresas: <https://emokymai.vu.lt/course/view.php?id=3208>.

A priedas

2.1 DI naudojimas

Naudotas „Google Gemini 3 Flash Preview“, kad patikrinti ar surašyti uždaviniai nėra etapai. Taip pat lentelėse, grafikuose pakeisti taškus į kablelius, kad būtų lietuviškas formatavimas.

Naudotas „Claude“ ieškant *R* funkcijų atitikmenų *Python* kalboje bei braižant grafikus, surašant lenteles ir *R* aplinkoje.

„ChatGPT“ skirtas gramatinėms klaidoms taisyti, *R Markdown* specifinių klaidų taisymui, rečiau naudojamų *R* paketų naudojimui.