



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

**Apsilankymo internetinėje parduotuvėje trukmės
prognozė, naudojant statistinius regresijos modelius**

Laboratorinis darbas

2 groupė 4 pogrupis
Nikita Demin, Lukas Janušauskas
Edvin Liubkevič, Martynas Zabitis

Vilnius
2026

Santrauka

Aktualumas

Nustatyti, kiek laiko naudotojas praleidžia internetinės parduotuvės svetainėje ir kokie faktoriai tai įtakoja, gali padėti nustatyti rinkodaros strategijas, nustatyti į ką atsižvelgti, norint prailginti šią trukmę. Taip pat, nustatę, kurie naudotojai tikėtinau praleis mažai laiko, galėsime nustatyti, kuriems naudotojams geriau pritaikyti kai kuriuos naudotojo sąsajos elementus (pvz. tokiems naudotojams naudoti greitesnius serverius).

Tikslas

Mūsų tikslas yra prognozuoti laiką, kurį naudotojai praleis svetainės puslapiuose.

Uždaviniai

Norint pasiekti savo užsibrėžto tikslo, išsikėlėme šiuos uždavinius:

1. Ištirti prie internetinės parduotuvės prisijungusių naudotojų sesijų charakteristikas, sąryšius su produktų puslapiuose praleista trukme.
2. Apmokyti ir optimizuoti statistinius regresijos modelius, skirtus prognozuoti su produktais susijusiuose puslapiuose praleistą trukmę.
3. Ištirti optimalaus modelio, prognozuojančio su produktais susijusiuose puslapiuose praleistą trukmę, požymių reikšmingumą, įtaką.

Lentelių sąrašas

1	Kiekybinių kintamųjų aprašymas	6
2	Kategorinių kintamųjų aprašymas	6
3	Kiekybinių kintamųjų skaitinės charakteristikos	7
4	Naršyklė dažnių lentelė	8
5	Srauto tipas dažnių lentelė	8
6	Spirmano koreliacijos su trukme apsilankymų produktų puslapiuose	9
7	Modelių palyginimas testavimo aibėje	18

Iliustracijų sąrašas

1	Skaidos diagramos, tarp kiekybinių kovariančių ir atsako - laiko, kurį naudotojas praleidžia internetinėje parduotuvėje	9
2	Stulpeliniai grafikai tarp kokybinių kovariančių ir laiko, praleisto produktų puslapiuose tiriamoje internetinėje parduotuvėje	10

Turinys

Santrauka	2
1 Tyrimas	6
1.1 Duomenų aprašymas	6
1.2 Duomenų paruošimas	6
1.3 Duomenų pradinė analizė	7
2 Duomenų padalijimas	10
3 Spline modeliai	10
3.1 B-splainas	10
3.2 Natūralus splainas	11
3.3 Glodusis splainas	12
4 GAM modeliai	13
5 Lokalios regresijos modelis	17
6 Modelių palyginimas	18
7 Šaltinių sąrašas	18
A priedas	20
7.1 DI naudojimas	20

1 Tyrimas

1.1 Duomenų aprašymas

Duomenys atsisiųsti iš *UCI Irvine Machine Learning Repository* (Sakar ir Kastro, 2018) su iš viso 10535 duomenų eilučių. Duomenų kintamieji aprašyti 1 ir 2 lentelėse. Duomenų rinkinį sudaro 1 metų informacija, kuri yra surinkta iš *columbia.com.tr* puslapio (Columbia, 2017).

1 lentelė: Kiekybinių kintamųjų aprašymas

Kintamojo pavadinimas	Kintamojo aprašymas
Administraciniai puslapiai	Kiek kartų lankytojas lankėsi paskyros valdymo puslapiuose.
Administracinių puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido paskyros valdymo puslapiuose.
Informaciniai puslapiai	Kiek kartų lankytojas lankėsi informaciniuose puslapiuose.
Informacinių puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido informaciniuose puslapiuose.
Produktų puslapių trukmė	Bendras laikas (sekundėmis), kurį lankytojas praleido parduodamų daiktų puslapiuose.
Atšokimo dažnis	Vidutinis lankytojo aplankytų puslapių skaičius, prieš pabaigiant sesiją, kai aplankyta tik viena prekė.
Išėjimo dažnis	Vidutinis lankytojo aplankytų puslapių skaičius, prieš pabaigiant sesiją, kai aplankyta daugiau nei viena prekė.
Puslapio vertė	Vidutinė lankytojo aplankytų puslapių vertė.
Ypatinga diena	Svetainės apsilankymo laiko artumas ypatingai dienai (pvz., šventei, išpardavimui).

2 lentelė: Kategorinių kintamųjų aprašymas

Kintamojo pavadinimas	Kintamojo aprašymas
Operacinė sistema	Lankytojo operacinė sistema.
Naršyklė	Lankytojo interneto naršyklė.
Regionas	Geografinis regionas, iš kurio lankytojas pradėjo sesiją.
Srauto tipas	Šaltinis, iš kurio lankytojas atvyko į svetainę (pvz., reklama kitame puslapyje, SMS, tiesioginis).
Lankytojo tipas	Lankytojo tipas: „Naujas lankytojas“, „Sugrįžtantis lankytojas“ ir „Kitas“
Savaitgalis	Ar apsilankymo data sutampa su savaitgalio.
Mėnuo	Apsilankymo datos mėnuo.
Pelningumas	Ar sesija buvo pelninga.

1.2 Duomenų paruošimas

Kintamieji „Operacinė sistema“, „Naršyklė“, „Regionas“ ir „Srauto tipas“ yra kategoriniai kintamieji, užkoduoti natūraliais skaičiais. Todėl juos pakeičiame atitinkamais faktoriais ir vėliau iš jų formuosime fiktyvius kintamuosius. Kintamasis „SpecialDay“, sprendžiant pagal reikšmes ir aprašymą yra ranginis kitamasis įgaunantis 6 skirtingas reikšmes: $\{0; 0, 2; \dots; 1\}$.

Duomenų aprašyme autoriai teigia, kad praleistų reikšmių nėra. Mes pasitiksliname, pasileidę atitinkamą R kodą - praleistų reikšmių nėra.

Loginių išskirčių tyrimas yra būtina dalis tyrimo, kadangi kai kurios iš duomenų rinkinyje esančios sesijos gali būti informacijos surinkimo robotai (*angl. web-scrapers*). Kad ištirtume logines išskirtis sudarėme skaitinių charakteristikų lentelę kiekybiniais kintamiesiems (3 lentelė). Joje naudojami standartiniai skaitinių charakteristikų žymėjimai: Min - minimumas, Q_n - n -tasis kvartilis, μ - vidurkis, Max - maksimumas. 3 lentelėje matome, jog nėra jokių nelogiškai išsiskiriančių reikšmių kintamuosiuose nesusijusiuose su apsilankymo trukme. Tačiau pastebėjome, kad kintamieji, susijusiems su sesijos trukme, turi loginių išskirčių, kurių tvarkybą pakomentuosim sekančiame paragrafe.

3 lentelė: Kiekybinių kintamųjų skaitinės charakteristikos

Kintamasis	Min	Q_1	Q_2	μ	Q_3	Max
Administraciniai puslapiai	0	0,00	1,00	2,32	4,00	27,00
Laikas administraciniuose puslapiuose	0	0,00	7,50	80,82	93,26	3398,75
Informaciniai puslapiai	0	0,00	0,00	0,50	0,00	24,00
Laikas informaciniuose puslapiuose	0	0,00	0,00	34,47	0,00	2549,38
Produktų puslapių trukmė	0	184,14	598,94	1194,75	1464,16	63973,52
Atšokimo dažnis	0	0,00	0,00	0,02	0,02	0,20
Išėjimo dažnis	0	0,01	0,03	0,04	0,05	0,20
Puslapio vertė	0	0,00	0,00	5,89	0,00	361,76
Ypatinga diena	0	0,00	0,00	0,06	0,00	1,00

Kad susitvarkytume su išskirtimis, išimsime stebėjimus, kai bendras praleistas laikas svetainėse yra nulis. Taip pat, pašalinsime stebėjimus, jei laikas tam tikram svetainių tipui yra nenulinis (pvz. nurodyta, kad administraciniuose puslapiuose praleistas tam tikras laikas), tačiau to tipo puslapių nebuvo aplankyta.

1.3 Duomenų pradinė analizė

Prieš apmokant regresijos modelius labai svarbu įsitikinti, kad kategorinio kintamojo lygmenų kartotinumai yra pakankamai dideli, nes lygmenims, turintiems mažai stebėjimų, negalėsime daryti išvadų. Toliau pašaliname kategorinių kintamųjų lygmenis, turinčius 5 ar mažiau stebėjimų.

Iš žemiau pateiktų lentelių, matome, kad yra probleminių faktorių lygmenų. „Naršyklės” devintas lygmuo, turi mažiau nei 5 stebėjimus. Tuo tarpu faktorius „Srauto tipas” turi tris probleminius lygmenis, kuriuos mes išimsime: būtent 12-as, 16-as ir 17-as. Šių faktorių dažnių lentelės pateiktos atitinkamai 4 ir 5 lentelėse.

4 lentelė: Naršyklė dažnių lentelė


Naršyklė	Dažnis	Santykinis dažnis (%)
1	2204	19.6
2	7323	65.0
3	94	0.8
4	672	6.0
5	430	3.8
6	161	1.4
7	44	0.4
8	120	1.1
9	1	0.0
10	156	1.4
11	6	0.1
12	10	0.1
13	49	0.4

5 lentelė: Srauto tipas dažnių lentelė

Srauto tipas	Dažnis	Santykinis dažnis (%)
1	2143	19.0
2	3725	33.1
3	1829	16.2
4	1000	8.9
5	249	2.2
6	402	3.6
7	37	0.3
8	325	2.9
9	36	0.3
10	413	3.7
11	230	2.0
12	1	0.0
13	637	5.7
14	13	0.1
15	28	0.2
16	3	0.0
17	1	0.0
18	8	0.1
19	16	0.1
20	174	1.5

Toliau tiriamie kiekybinių požymių sąryšius su atsaku - laiku, praleistu produktų puslapiuose. Sąryšius tiriamie, pasitelkę sklaidos diagramų groteles (žr. 1 pav.), kurių x ir y ašims pritaikyta logaritminė transformacija. Pastebime, kad turime tam tikrą koreliaciją su visomis potencialiomis kovariantėmis išskyrus kintamąjį „Ypatinga diena“. Aplankytų administracinių, informacinių ir produktų puslapių skaičius natūraliai reiškia didesnę trukmę, praleistą produktų puslapiuose, taigi pastebime teigiamą koreliaciją. Neigiamą puslapių kokybę atskleidžiančios „Google Analytics“ metrikos „Atšokimo dažnis ir Išėjimo dažnis“ turi neigiamą koreliaciją su. Kas irgi yra akivaizdu - kuo naudotojo aplankyti puslapiai yra labiau linkę būti sesijos pabaigimo priežastimi ar būti praversti nesukūrus jokios užklauso puslapyje, tuo puslapiai yra labiau linkę skatinti naudotoją atsijungti nuo internetinės parduotuvės. Tuo tarpu puslapio Google Analytics vertė turi neigiamą koreliaciją su atsaku, kas nėra intuityvu. Tai galimai yra konkurentų puslapiai, turintys aukštus įvertinimus ar kita problema, į kurią reikėtų iš dalikinės pasižiūrėti.

Šias išvadas patvirtina ir 6 lentelė.



1 pav.: Sklaidos diagramos, tarp kiekybinių kovariančių ir atsako - laiko, kurį naudotojas praleidžia internetinėje parduotuvėje


6 lentelė: Spirmano koreliacijos su trukme apsilankymų produktų puslapiuose

Kintamasis	Spearmano koeficientas
Administraciniai puslapiai	0.370
Laikas administraciniuose puslapiuose	0.36
Informaciniai puslapiai	0.352
Laikas informaciniuose puslapiuose	0.35
Atšokimo dažnis	0.106
Išėjimo dažnis	-0.375
Puslapio vertė	0.339
Ypatinga diena	-0.052

Iš stulpelinių grafikų, su 95 % procentilinių savirankos intervalais, (žr. 2 pav.) pastebime, kad:

1. Lankytojo tipas, mėnuo, kurio metu fiksuota naudotojo sesija, naudotojo naršyklė ir naudojama operacinė sistema turi reikšmingai skirtingus vidurkius praleisto laiko produktų puslapiuose.
2. Laikas, praleistas produktų puslapiuose vidutiniškai nepriklauso nuo to, ar sesija fiksuota savaitgalį, ar ne.

3. Tik pavieniai regionai išsiskiria laiko, praleisto produktų puslapiuose prasme, tačiau bendrai paėmus labai panašus atsako vidurkis visuose lygmenyse.



2 pav.: Stulpeliniai grafikai tarp kokybinių kovariančių ir laiko, praleisto produktų puslapiuose tiriamoje internetinėje parduotuvėje

2 Duomenų padalijimas

3 Spline modeliai

3.1 B-splainas

B-splaino modeliui turėjome parinkti vieną optimalią kovariantę ir mazgų skaičių su kuriuo gauname mažiausią RSME. Geriausios kovariantės ieškojimui naudojame visus stulpelius išskyrus patį „ProductRelated_Duration“, kurį norime prognozuoti ir atmetus produktų puslapių peržiūrų skaičių, kadangi ši viena kovariantė per daug gerai įvertina praleistą laiką produktų puslapiuose. Mazgų galimas rėžis buvo nuo 3 iki 15, atkreipiant dėmesį, kad didelis mazgų skaičius gali reikšti modelio per didelį prisitaikymą prie duomenų (angl. over-fitting). Kaip matome @ref(tab:best-rmse-table) lentelėje, mažiausią RMSE gavome su „Administrative_Duration“ kovariante ir 8 mazgais, o prasčiausiai naudojant B-splaino modelį gauti rezultatai su specialios dienos kintamuoju. Taip pat, geri rezultatai gauti su „BounceRates“ kovariante.

```
## Best B-Spline covariate: Administrative_Duration
```

```
## Best B-Spline df: 8
```

```
##               var df    rmse
## 1 Administrative_Duration 8 1729.831
```

```
## 2          BounceRates 10 1793.042
## 3 Informational_Duration 7 1824.938
## 4          Administrative 3 1850.243
## 5          PageValues 15 1863.105
## 6          Informational 6 1885.171
## 7          ExitRates 4 1925.189
## 8          SpecialDay 5 1983.379

##
## Call:
## lm(formula = ProductRelated_Duration ~ bs(Administrative_Duration,
##     df = 4), data = train_df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -20049.4   -751.4   -453.7    266.6   24094.5
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                   769.36      28.08   27.403 < 2e-16 ***
## bs(Administrative_Duration, df = 4)1    228.93      49.71    4.606 4.17e-06 ***
## bs(Administrative_Duration, df = 4)2   7858.81     353.78   22.214 < 2e-16 ***
## bs(Administrative_Duration, df = 4)3 -17409.88    1099.19  -15.839 < 2e-16 ***
## bs(Administrative_Duration, df = 4)4  60997.25     1434.23   42.530 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1723 on 8443 degrees of freedom
## Multiple R-squared:  0.2537, Adjusted R-squared:  0.2534
## F-statistic: 717.7 on 4 and 8443 DF,  p-value: < 2.2e-16
```

3.2 Natūralus splainas

Natūralus splainas turi tam tikras taisykles, dėl kurių šio splaino modelio kraštai yra tiesiški.~? Kaip ir b-splaino modelio atveju, mes ieškome tokios kovariantės ir mazgų skaičiaus, kad gautume mažiausią RSME. ?? lentelės rezultatai rodo, kad mažiausias RSME gautas su „BounceRates“ ir 8 mazgais. Skirtingai nei~?? lentelėje, kur geriausi rezultatai gauti su administracinių puslapių peržiūros laiku, su natūralių splainų modeliu šių puslapių peržiūrų laikas yra tik penktoje vietoje iš aštuonių. Prasčiausi rezultatai vėl gauti su specialųjų dienų kintamuoju.

```
## Geriausia normalaus splaino kovariantė: BounceRates
```

```
## Geriausias mazgų skaičius:      8
```

```
##          var df      rmse
## 1          BounceRates 8 1776.367
## 2          Administrative 3 1827.952
## 3          Informational 8 1838.424
## 4          PageValues 13 1845.385
## 5 Administrative_Duration 15 1847.630
## 6 Informational_Duration 15 1861.160
## 7          ExitRates 15 1904.781
## 8          SpecialDay 10 1964.963
```

```
##
## Call:
## lm(formula = ProductRelated_Duration ~ ns(BounceRates, df = 8),
##     data = train_df)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -3703    -691    -351     245   59813
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      753.39      28.31  26.615 < 2e-16 ***
## ns(BounceRates, df = 8)1  3750.84     466.76   8.036 1.05e-15 ***
## ns(BounceRates, df = 8)2  3367.25     220.79  15.251 < 2e-16 ***
## ns(BounceRates, df = 8)3  2225.68     147.84  15.055 < 2e-16 ***
## ns(BounceRates, df = 8)4  1347.03     108.11  12.460 < 2e-16 ***
## ns(BounceRates, df = 8)5   463.02      82.24   5.630 1.86e-08 ***
## ns(BounceRates, df = 8)6 -3958.56     569.57  -6.950 3.92e-12 ***
## ns(BounceRates, df = 8)7  5554.47    1132.21   4.906 9.48e-07 ***
## ns(BounceRates, df = 8)8 -3548.03     685.22  -5.178 2.30e-07 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1796 on 8439 degrees of freedom
## Multiple R-squared:  0.1899, Adjusted R-squared:  0.1891
## F-statistic: 247.2 on 8 and 8439 DF,  p-value: < 2.2e-16
```

3.3 Glodusis splainas

Skirtingai nei b-splainai, kurie reguliuoja lankstumą fiksuodami konkretų mazgų skaičių, glodieji splainai mazgus išdėsto kiekviename unikaliame duomenų stebėjime, o modelio sudėtingumą valdo per reguliarizavimo (lamda) parametą. Šį kart geriausiai rezultatai gauti su „Administrative_Duration“ kintamuoju ir lamda = 0.0085 reiškme (žr~??).

```
## Geriausia glodžiųjų splainų kovariantė: Administrative_Duration
```

```
## Geriausias glodžiųjų splainų mazgų skaičius: 3
```

```
## Geriausia lambda vertė: 0.008531679
```

```
##              var df      lambda      rmse
## 1 Administrative_Duration  3 0.008531679 1742.072
## 2          BounceRates    3 0.000001000 1793.220
## 3      Administrative    3 0.621016942 1838.506
## 4          ExitRates      3 0.000001000 1913.889
## 5      Informational      3 0.000001000      NaN
## 6 Informational_Duration  3 0.000001000      NaN
## 7          PageValues     3 0.000001000      NaN
## 8          SpecialDay     3 0.000001000      NaN
```

```
## R-squared: 0.2575
```

```
## RMSE:      1718.128
```


```
## df used:    7.548962
```





```
## lambda:     0.003290345
```



4 GAM modeliai

Pirmame GAM modelyje kiekvienam skaitiniam kintamajam taikomi glodinantys splainai, o konkrečiai – thin plate regression splines. Tai yra numatytasis splainų tipas, naudojamas mgcv pakete. Šie splainai pasižymi tuo, kad nereikalauja iš anksto parinkti mazgų (angl. knots) vietų – jų forma automatiškai nustatoma iš duomenų.


Antru atveju sudaromas modelis, kuriame naudojami du skirtingi netiesinių ryšių modeliavimui skirti metodai. Daliai kintamųjų taikomi regresiniai splainai, kurių sudėtingumas yra nustatomas iš anksto per laisvės laipsnių parametą. Kitai kintamųjų daliai taikoma lokali regresija.















gam::lo(Administrative_Duration, span = 0.7)








5 Lokalias regresijos modelis

```
## Geriausias span: 0.9
```

```
## Geriausias pcaComp: 2
```

RMSE: 1679.594



6 Modelių palyginimas

7 lentelė: Modelių palyginimas testavimo aibėje

Modelis	RMSE	R ²	MAE	SMAPE (%)
B-Spline	1746.71	0.0860	1034.87	88.28
Natural Spline	1614.16	0.2195	918.35	81.70
GAM	1562.24	0.2689	894.18	83.31
GAM splainai + lokali	1667.75	0.1668	981.05	84.81
Lokalioji regresija	1615.16	0.2185	951.53	85.91

```
##          df      AIC
## bs_model 6.00000 149887.3
## ns_model 10.00000 150589.1
## gam_model 87.85418 147017.9
```

7 Šaltinių sąrašas

Columbia (2017). Adresas: <https://www.columbia.com.tr/>.

Regresinės analizės kurso medžiaga (2026). Adresas: <https://emokymai.vu.lt/course/view.php?id=8011>.

Sakar, C. ir Kastro, Y. (2018) „Online Shoppers Purchasing Intention Dataset“. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5F88Q>.

Tiesinių modelių kurso medžiaga (2025). Adresas: <https://emokymai.vu.lt/course/view.php?id=3208>.

A priedas

7.1 DI naudojimas

Naudotas „Google Gemini 3 Flash Preview“, kad patikrinti ar surašyti uždaviniai nėra etapai. Taip pat lentelėse, grafikuose pakeisti taškus į kablelius, kad būtų lietuviškas formatavimas.

Naudotas „Claude“ ieškant *R* funkcijų atitikmenų *Python* kalboje bei braižant grafikus, surašant lenteles ir *R* aplinkoje.

„ChatGPT“ skirtas gramatinėms klaidoms taisyti, *R Markdown* specifinių klaidų taisymui, rečiau naudojamų *R* paketų naudojimui.